

Asymptotiske egenskaber ved OLS

Økonometri A

Bertel Schjerning

Motivation

Konsistens (W5.1)

Asymptotisk fordeling af OLS (W5.2)

Asymptotisk efficiens af OLS (W5.3)

Asymptotisk inferens

Motivation

Motivation: Små og store stikprøver

Indtil videre har vi behandlet de **eksakte** egenskaberne ved OLS.

Dvs. egenskaber som holder uanset størrelsen af stikprøve (n), hvor vi har vist at

- MLR.1-MLR.4 \Rightarrow OLS er middelret
- MLR.1-MLR.5 \Rightarrow OLS er BLUE + formel for varians.
- MLR.1-MLR.6 \Rightarrow OLS er normalfordelt, og vi kan lave inferens med t- og F-test.

Disse resultater gælder for alle n , også når n er lille.

I denne lektion vil vi undersøge egenskaberne ved OLS når n går mod uendelig.

- Særligt kan vi undvære MLR.6 når $n \rightarrow \infty$

Konsistens

Definition (se Appendix C-3):

Lad W_n være en estimator af θ baseret på n observationer Y_1, Y_2, \dots, Y_n . Så er W_n en **konsistent estimator** for θ , hvis

$$P(|W_n - \theta| > \varepsilon) \rightarrow 0 \text{ for } n \rightarrow \infty.$$

Vi skriver også, at W_n konvergerer i sandsynlighed mod θ

$$p \lim W_n = \theta$$

Hvis dette ikke gælder, siger vi, at W_n er **inkonsistent**.

Konsistens er en egenskab for estimatoren, når $n \rightarrow \infty$.

Vi kræver normalt at en estimator skal være konsistent.

Konsistens vs. middelfret

Det kan være nyttigt at tænke på konsistens, som bestående af to dele:

- $E(W_n) \rightarrow \theta$ for $n \rightarrow \infty$
- $\text{var}(W_n) \rightarrow 0$ for $n \rightarrow \infty$


Det betyder at konsistens ikke er det samme som middelfret.

Vi kan fx have:

- Middelfrette estimatorer, som ikke bliver mere koncentreret omkring θ ($\text{var}(W_n) \not\rightarrow 0$)
- Konsistente estimatorer, hvor $E(W_n) \neq \theta$ som for alle " $n < \infty$ "

Konsistens vs. middelret

FIGURE 5.1 Sampling distributions of $\hat{\beta}_1$ for sample sizes $n_1 < n_2 < n_3$.



Store tals lov

Lad Y_1, Y_2, \dots, Y_n være uafhængige og identisk fordelte stokastiske variable med $E(Y_i) = \mu$. Da er gennemsnittet $\bar{Y}_n = \frac{1}{n} \sum Y_i$ en konsistent estimator for μ .

$$p \lim \bar{Y}_n = \mu$$

Regneregler for $p\lim(\cdot)$ og $E(\cdot)$

Regneregler for $p\lim$:

1. For alle kontinuerte funktioner g : $p\lim(g(W_n)) = g(p\lim(W_n))$
2. Hvis $p\lim(G_n) = \alpha$ og $p\lim(W_n) = \beta$, så:
 - 2.1 $p\lim(G_n + W_n) = \alpha + \beta$
 - 2.2 $p\lim(G_n \cdot W_n) = \alpha \cdot \beta$
 - 2.3 $p\lim\left(\frac{G_n}{W_n}\right) = \frac{\alpha}{\beta}$, hvis $\beta \neq 0$

Regneregler for forventninger:

- $E[G_n + W_n] = E[G_n] + E[W_n]$
- Men $E[g(W_n)] \neq g(E[W_n])$, medmindre g er lineær
- Hvis g er konveks, så gælder $E[g(W_n)] \geq g(E[W_n])$
- Forventninger påvirkes af varians (Jensen's ulighed)
- Plims tillader ikke-lineære transformationer, fordi variansen forsvinder i grænsen.

Mere om sandsynlighedsgrænser

Lad F_n være en funktion af $Y_1, Y_2, Y_3, \dots, Y_n$ stokatiske variable.

Hvis $P(|F_n - \theta| < \varepsilon) \rightarrow 1$ når $n \rightarrow \infty$, så er $p \lim F_n = \theta$.

Eksempler:

$F_n = \frac{1}{n} \sum_{i=1}^n Y_i$ Konvergerer mod middelværdien,
så $p \lim F_n = \mu$

$F_n = \sum_{i=1}^n Y_i$ Konvergerer ikke, men går mod uendelig,
så der findes ingen sandsynlighedsgrænse.

Mere om sandsynlighedsgrænser

Vi kommer til at bruge følgende egenskaber af p lim:

$$p \lim \frac{1}{n} \sum_i Y_i = E(Y)$$

$$p \lim \frac{1}{n} \sum_i (Y_i - \bar{Y})^2 = \text{Var}(Y)$$

$$p \lim \frac{1}{n} \sum_i (Y_i - \bar{Y})(X_i - \bar{X}) = \text{Cov}(Y, X)$$

Sandsynlighedsgrænse for hældningskoefficienten i SLR:

$$\begin{aligned} p \lim \left[\frac{\frac{1}{n} \sum_i (Y_i - \bar{Y})(X_i - \bar{X})}{\frac{1}{n} \sum_i (X_i - \bar{X})^2} \right] \\ = \frac{p \lim \left(\frac{1}{n} \sum_i (Y_i - \bar{Y})(X_i - \bar{X}) \right)}{p \lim \left(\frac{1}{n} \sum_i (X_i - \bar{X})^2 \right)} = \frac{\text{Cov}(Y, X)}{\text{Var}(X)} \end{aligned}$$

Ny antagelse: MLR.4'

For at opnå at OLS er unbiased, skal vi bruge MLR.1-MLR.4.

Men for at opnå konsistens, kan vi slækkke på MLR.4.

MLR.4 Den betingede middelværdi af fejlleddet skal være 0:

$$E(u|x_1, x_2, \dots, x_k) = 0.$$

På matrixform: $E(\mathbf{u}|\mathbf{X}) = \mathbf{0}$

MLR.4' Fejlleddet har middelværdi 0 og er *ukorreleret* med alle x_j

$$E(u) = 0 \text{ og } \text{cov}(x_j, u) = 0 \text{ for alle } j = 1, 2, \dots, k$$

På matrixform: $E(\mathbf{u}) = \mathbf{0}$ og $\text{Cov}(\mathbf{u}, \mathbf{X}) = \mathbf{0}$

Bemærk:

- MLR.4 er stærkere end MLR.4', da $E(\mathbf{u}|\mathbf{X}) = \mathbf{0}$ kræver, at *enhver funktion* af x_j er ukorreleret med fejlleddet.

Teorem 5.1: OLS estimatoren er konsistent

Under antagelserne MLR.1-MLR.3 og MLR.4' er OLS estimatoren $\hat{\beta}_j$ en konsistent estimator for β_j for alle $j = 0, 1, \dots, k$

$$p \lim \hat{\beta} = \beta$$

Bemærk:

- **Konsistens** betyder, at OLS-estimatoren $\hat{\beta}$ konvergerer i sandsynlighed mod β , når $n \rightarrow \infty$.
- Vi kan *ikke* etablere, at $E[\mathbf{y}|\mathbf{X}] = \mathbf{X}\beta$ uden $E(\mathbf{u}|\mathbf{X}) = \mathbf{0}$ (MLR.4).
- **Partielle effekter er ikke identificeret uden MLR.4:**
 $\partial E[\mathbf{y}|\mathbf{X}]/\partial x_j \neq \beta_j$, hvis $\partial E[\mathbf{u}|\mathbf{X}]/\partial x_j \neq 0$.
- Under MLR.4' kan **prediktioner** baseret på $E[\mathbf{y}|\mathbf{X}] = \mathbf{X}\beta$ være **biased**, da vi ikke har garanti for, at $E(\mathbf{u}|\mathbf{X}) = \mathbf{0}$.

OLS er konsistent: Bevis (SLR)

Sandsynlighedsgrænse for $\hat{\beta}_1$ i SLR

$$p \lim \hat{\beta}_1 = \beta_1 + p \lim \frac{\frac{1}{n} \sum_{i=1}^n u(x_i - \bar{x})}{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2} = \beta_1 + \frac{p \lim \frac{1}{n} \sum_{i=1}^n u(x_i - \bar{x})}{p \lim \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2}$$

Under MLR.2, MLR.3 og MLR.4' har vi

- $p \lim \frac{1}{n} \sum_{i=1}^n x_i u_i = cov(u, x) = 0$ (MLR.4')
- $p \lim \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 = var(x) \neq 0$ (MLR.3)

Derfor

$$p \lim \hat{\beta}_1 = \beta_1$$

- For SLR er $\hat{\beta}_1$ konsistent for β_1 under MLR.1-MLR.3 og MLR.4'.
- Hvad med MLR?

OLS er konsistent: Bevis (MLR) 1/2

Indsæt $\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{u}$ (MLR.1) i OLS-estimatoren:

$$\begin{aligned}\hat{\boldsymbol{\beta}} &= (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'(\mathbf{X}\boldsymbol{\beta} + \mathbf{u}) \\ &= (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{X}\boldsymbol{\beta} + (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{u} \\ &= \boldsymbol{\beta} + (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{u}\end{aligned}$$

Her bruger vi antagelsen om ingen perfekt multikollinearitet (MLR.3), som sikrer, at $\mathbf{X}'\mathbf{X}$ er inverterbar.

OLS er konsistent Bevis (MLR) 2/2

Nu tager vi p lim af OLS-estimatoren:

$$p \lim \hat{\beta} = p \lim (\beta + (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{u})$$

Vi normaliserer $\mathbf{X}'\mathbf{X}$ ved n , så sandsynlighedsgrænsen eksisterer:

$$p \lim \hat{\beta} = \beta + \left(p \lim \frac{1}{n} \mathbf{X}'\mathbf{X} \right)^{-1} \cdot p \lim \frac{1}{n} \mathbf{X}'\mathbf{u}$$

Da $p \lim \frac{1}{n} \mathbf{X}'\mathbf{u} = 0$ (MLR.4' og MLR.2), og $p \lim \frac{1}{n} \mathbf{X}'\mathbf{X}$ er en positiv definit matrix med fuld rang (MLR.3), får vi:

$$p \lim \hat{\beta} = \beta + \left(p \lim \frac{1}{n} \mathbf{X}'\mathbf{X} \right)^{-1} \cdot 0 = \beta$$

OLS-estimatoren er altså konsistent under MLR.1-MLR.3 og MLR.4'.

Hvornår er OLS inkonsistent?

OLS er inkonsistent, hvis

$$\text{cov}(u, x_j) \neq 0$$

hvilket sker, når MLR.4' ikke holder. Dette indebærer, at fejlleddet u er korreleret med mindst en af de forklarende variable.

Den resulterende **asymptotiske bias** er givet ved:

$$p \lim \hat{\beta}_j - \beta_j = \frac{\text{cov}(\hat{r}_{ij}, u)}{\text{var}(\hat{r}_{ij})}$$

hvor \hat{r}_j er residualerne fra en regression af x_j på alle de andre x' er.

Problemet forsvinder ikke, selvom $n \rightarrow \infty$, da biasen er asymptotisk.

Quiz:

Antag at $\hat{\beta}_0$, $\hat{\beta}_1$ og $\hat{\sigma}^2$ er estimerne fra en simple lineær regressionsmodel, som opfylder SLR.1-SLR.5.

Afgør om følgende alternative estimators er middelfrette og/eller konsistente:

1. $\tilde{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i)^2.$

2. $\tilde{\beta}_1 = \frac{\sum_{i=50}^n y_i (x_i - \bar{x})}{\sum_{i=50}^n x_i (x_i - \bar{x})}$
(OLS estimatoren, hvor man ikke bruger de første 50 obs.).

3. $\check{\beta}_1 = \frac{\sum_{i=1}^{50} y_i (x_i - \bar{x})}{\sum_{i=1}^{50} x_i (x_i - \bar{x})}$
(OLS estimatoren, hvor man kun anvender de første 50 obs.).

Asymptotisk fordeling af OLS

Asymptotisk fordeling af OLS

Teorem 5.2: OLS estimatoren er asymptotisk normalfordelt

Under antagelse MLR.1-MLR.5 gælder følgende:

1. $\sqrt{n}(\hat{\beta}_j - \beta_j) \overset{a}{\sim} N(0, \sigma^2/a_j^2)$, hvor
 $a_j^2 = p \lim \left(\frac{1}{n} \sum_{i=1}^n \hat{r}_{ij}^2 \right) = \text{Var}(\hat{r}_j)$
2. $\hat{\sigma}^2$ er en konsistent estimator for $\sigma^2 = \text{Var}(u)$.
3. $\frac{\hat{\beta}_j - \beta_j}{sd(\hat{\beta}_j)} \overset{a}{\sim} N(0, 1)$ og $\frac{\hat{\beta}_j - \beta_j}{se(\hat{\beta}_j)} \overset{a}{\sim} N(0, 1)$

Teorem 5.2 viser, at MLR.6 ikke er nødvendig, når datasættet er "stort", da estimatoren er asymptotisk normalfordelt uden antagelsen om normalfordelte fejlede.

Asymptotisk fordeling af OLS (Matrixform)

Teorem 5.2: OLS estimatoren er asymptotisk normalfordelt

Under antagelse MLR.1-MLR.5 gælder følgende:

$$\sqrt{n}(\hat{\beta} - \beta) \overset{a}{\approx} N(0, \sigma A^{-1}),$$

hvor $\hat{\beta}$ er OLS-estimatoren, σ^2 er variansen af fejleddet u og $A = p \lim \frac{1}{n}(X'X) = p \lim \frac{1}{n} \sum_{i=1}^n (x_i'x_i) = E(x_i'x_i)$ er en ikke singulær matrix (MLR.3), som ikke afhænger af n

- $\hat{\sigma}^2$ er en konsistent estimator for $\sigma^2 = \text{Var}(u)$.
- $\overset{a}{\approx}$ er en forkortelse for "asymptotisk fordelt som"
- $sd(\hat{\beta})$ findes som kvadratroden af diagonal elementerne i $\sigma^2(X'X)^{-1}$, som er en konsistent estimator for den asymptotiske varians-kovarians matrix for β

Asymptotisk fordeling af OLS

Hvorfor ganger vi med \sqrt{n} ?

Ihukom formelen for den estimerede varians af OLS

$$\text{var}(\hat{\beta}_j|X) = \frac{\hat{\sigma}^2}{SSR_j} = \frac{\hat{\sigma}^2}{SST_j(1 - R_j^2)}$$

Når $n \rightarrow \infty$ gælder

- $\hat{\sigma}^2 \rightarrow \sigma^2$
- $R_j^2 \rightarrow \alpha \in (0, 1)$
- $SST_j \rightarrow n \cdot \text{var}(x_j)$

Dvs. variansen af OLS konvergerer mod 0 med hastighed $1/n$.

Standardfejlen konvergerer med hastighed $1/\sqrt{n}$

Hvornår er n stor nok?

Hvornår kan man anvende de asymptotiske resultater (hvornår er n stor nok)?

- Man kan ikke sige noget generelt om, hvornår n er stor nok.
- Det afhænger af u (hvor meget u afviger fra normalfordelingen).
- Næste gang skal vi se på simulationer, som kan hjælpe med at besvare dette spørgsmål.
- I de fleste praktiske økonometriske analyser med flere mio. observationer, antager folk at OLS er normalfordelt uden at blinke.

Asymptotisk efficiens af OLS

Efficiens drejer sig om at sammenligne variansen af estimatorer.

Definition af relativ efficiens (se appendix C-2e):

Hvis W_1 og W_2 er to konsistente estimatorer for parameteren θ , så er W_1 mere efficient end W_2 , hvis der gælder $Avar(W_1) \leq Avar(W_2)$ for alle θ og $Avar(W_1) < Avar(W_2)$ for mindst et θ .

Efficiens drejer sig om at sammenligne variansen af estimatorer.

Definition af relativ efficiens (se appendix C-2e):

Hvis W_1 og W_2 er to konsistente estimatorer for parameteren θ , så er W_1 mere efficient end W_2 , hvis der gælder $Avar(W_1) \leq Avar(W_2)$ for alle θ og $Avar(W_1) < Avar(W_2)$ for mindst et θ .

Bemærk: Det er ikke altid at den ene estimator er mere efficient end den anden.

- Fx hvis $var(W_1) < Var(W_2)$ for $\theta < a$ og omvendt for $\theta > a$

Teorem 5.3: OLS estimatoren asymptotisk efficient

Under antagelse MLR.1-MLR.5 vil en hvilken som helst anden konsistente estimator $\tilde{\beta}$ have større asymptotisk varians end OLS estimatoren.

Det er ikke så overraskende, når OLS under MLR1-MLR.5 er BLUE for alle n .

Asymptotisk inferens

t-test er asymptotisk normalfordelt (recap)

Under asymptotisk normalitet kan vi teste $H_0 : \beta_j = a$

Vi har set, at under MLR.1-MLR.5 gælder:

$$\sqrt{n}(\hat{\beta} - \beta) \overset{a}{\sim} N(0, \sigma A^{-1}),$$

$$\text{hvor } A = p \lim \frac{1}{n}(X'X) = p \lim \frac{1}{n} \sum_{i=1}^n (x_i' x_i)$$

Under nullhypotesen $H_0 : \beta_j = a$:

$$t = \frac{\hat{\beta}_j - a}{\text{se}(\hat{\beta}_j)} \overset{a}{\sim} N(0, 1)$$

$$\text{hvor } \text{se}(\hat{\beta}_j) = \hat{\sigma} \sqrt{(X'X)^{-1}_{jj}}$$

- Finite sample: $t \sim t_{n-p}$ (kræver normalitet, MLR.6).
- Asymptotisk: $t \overset{a}{\sim} N(0, 1)$ (kun MLR.1-MLR.5).

F-test som fit-sammenligning

Idé: Test af q lineære restriktioner $H_0 : R\beta = r$.

$$F = \frac{(SSR_r - SSR_{ur})/q}{SSR_{ur}/(n-p)}$$

- Finite sample (med normalitet): $F \sim F_{q,n-p}$.

- Asymptotisk:

$$qF \stackrel{a}{\sim} \chi_q^2.$$

- Intuition: sammenligner fit i restrikeret (R) og urestrikeret (UR) model.

Tre klassiske testfamilier

	Model	Teststørrelse	Fordeling under H_0
Wald / t-test (for $q=1$)	UR	Afviigelser i parametre	$\chi_q^2 / N(0, 1)$
F/LR (Fit-sammenligning)	UR + R	Forskel i objective (SSR/logL)	$\chi_q^2 / F_{q,n-p}$
LM (Score)	R	Score-gradient i R-model	χ_q^2

Asymptotisk ækvivalens: Wald, LR/F og LM \Rightarrow samme konklusion for store n .

Wald test - Parameter restriktioner på urestrikeret model

Hypotesetest med flere restriktioner:

$$H_0 : \mathbf{R}\beta = \mathbf{r} \quad \text{mod} \quad H_1 : \mathbf{R}\beta \neq \mathbf{r}.$$

hvor:

- \mathbf{R} er en $q \times (k + 1)$ restriktionsmatrice,
- \mathbf{r} er en $q \times 1$ vektor.

Wald-teststørrelsen (Se Wooldridge E-4a):

$$W = (\mathbf{R}\hat{\beta} - \mathbf{r})' \left[\mathbf{R}\widehat{\text{var}}(\hat{\beta}|\mathbf{X})\mathbf{R}' \right]^{-1} (\mathbf{R}\hat{\beta} - \mathbf{r}) \sim \chi_q^2,$$

- $\widehat{\text{var}}(\hat{\beta}|\mathbf{X}) = \hat{\sigma}^2(\mathbf{X}'\mathbf{X})^{-1}$ (Under MLR.5: homoskedasticitet)
- W er asymptotisk χ^2 -fordelt med q frihedsgrader ($\#$ restriktioner)
- $q \leq k + 1$ (vi kan ikke lave flere restriktioner end parametre).

Wald test - Eksempel med én restriktion

Hypotese med én restriktion på flere parametre:

$$H_0 : \mathbf{R}\boldsymbol{\beta} = \mathbf{r} \quad \text{mod} \quad H_1 : \mathbf{R}\boldsymbol{\beta} \neq \mathbf{r}.$$

Eksempel med $q = 1$ restriktion på 2 parametre:

$$H_0 : \beta_1 = \beta_2 \quad \text{mod} \quad H_1 : \beta_1 \neq \beta_2$$

giver:

$$\mathbf{R} = (0 \ 1 \ -1), \quad \boldsymbol{\beta} = (\beta_0 \ \beta_1 \ \beta_2)', \quad \mathbf{r} = 0$$

Udregning af $\mathbf{R}\boldsymbol{\beta} - \mathbf{r}$:

$$\mathbf{R}\boldsymbol{\beta} - \mathbf{r} = \beta_1 - \beta_2$$

Bemærk at $q = 1$ og derfor er W kvadratet på en t -størrelse:

$$W = \frac{(\hat{\beta}_1 - \hat{\beta}_2)^2}{\hat{\sigma}^2 [\mathbf{R}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{R}']} = \frac{(\hat{\beta}_1 - \hat{\beta}_2)^2}{\widehat{\text{var}}(\hat{\beta}_1 - \hat{\beta}_2)} \sim \chi_1^2$$

Wald test - Eksempel med flere restriktioner

Hypotese med flere restriktioner:

$$H_0 : \mathbf{R}\beta = \mathbf{r} \quad \text{mod} \quad H_1 : \mathbf{R}\beta \neq \mathbf{r}.$$

Eksempel med $q = 2$ restriktioner på 2 parametre:

$$H_0 : \beta_1 = 1 \text{ og } \beta_2 = 2 \quad \text{mod} \quad H_1 : \beta_1 \neq 1 \text{ eller } \beta_2 \neq 2$$

giver:

$$\mathbf{R} = \begin{pmatrix} 0 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix}, \quad \beta = \begin{pmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \end{pmatrix}, \quad \mathbf{r} = \begin{pmatrix} 1 \\ 2 \end{pmatrix}$$

$$\mathbf{R}\beta - \mathbf{r} = \begin{pmatrix} \beta_1 - 1 \\ \beta_2 - 2 \end{pmatrix}$$

Lagrange Multiplier (LM) test

Lagrange Multiplier (LM) testet er et alternativ til Wald og F-testet ved multiple lineære restriktioner.

Betragt en urestrikeret model

$$y = \beta_0 + \beta_1 x_1 + \dots + \beta_{k-q} x_{k-q} + \beta_{k-q+1} x_{k-q+1} \dots + \beta_k x_k + u.$$

Hypotese $H_0 : \beta_{k-q+1} = \dots = \beta_k = 0$.

Lagrange Multiplier (LM) test

Lagrange Multiplier (LM) testet er et alternativ til Wald og F-testet ved multiple lineære restriktioner.

Betragt en urestrikeret model

$$y = \beta_0 + \beta_1 x_1 + \dots + \beta_{k-q} x_{k-q} + \beta_{k-q+1} x_{k-q+1} + \dots + \beta_k x_k + u.$$

Hypotese $H_0 : \beta_{k-q+1} = \dots = \beta_k = 0$.

Ideen bag LM-testet:

Hvis H_0 er opfyldt er residualerne (\tilde{u}) fra den restrikerede model (uden x_{k-q+1}, \dots, x_k) ukorreleret med x_{k-q+1}, \dots, x_k .

- Hvis $\beta_{k-q+1} = \dots = \beta_k = 0$, så ligger x_{k-q+1}, \dots, x_k ikke i \tilde{u} .

Lagrange Multiplier (LM) test

Lagrange Multiplier (LM) testet er et alternativ til Wald og F-testet ved multiple lineære restriktioner.

Betragt en urestrikeret model

$$y = \beta_0 + \beta_1 x_1 + \dots + \beta_{k-q} x_{k-q} + \beta_{k-q+1} x_{k-q+1} + \dots + \beta_k x_k + u.$$

Hypotese $H_0 : \beta_{k-q+1} = \dots = \beta_k = 0$.

Ideen bag LM-testet:

Hvis H_0 er opfyldt er residualerne (\tilde{u}) fra den restrikerede model (uden x_{k-q+1}, \dots, x_k) ukorreleret med x_{k-q+1}, \dots, x_k .

- Hvis $\beta_{k-q+1} = \dots = \beta_k = 0$, så ligger x_{k-q+1}, \dots, x_k ikke i \tilde{u} .

Fordelen ved LM-testet er at man ikke behøver at estimere den urestrikerede model.

Lagrange Multiplier (LM) test

Procedure:

1. Estimer den restriktede model (modellen under H_0) med OLS:

$$y = \tilde{\beta}_0 + \tilde{\beta}_1 x_1 + \dots + \tilde{\beta}_{k-q} x_{k-q} + \tilde{u}.$$

2. Udregn residualerne fra den restriktede model \tilde{u} .
3. Regresser \tilde{u} på x_{k-q+1}, \dots, x_k og gem R^2 .
4. Teststørrelsen er bestemt ved $LM = n \cdot R^2$. LM testet er asymptotisk $\chi^2_{(q)}$, hvor q er antallet af restriktioner.
5. Find den kritiske værdi eller p-værdien ved at benytte $\chi^2_{(q)}$ til at bestemme om H_0 kan afvises.

F-testet og LM testet er asymptotisk equivalente, men kan være forskellige i endelige (små) datasæt.

Opsummering

Nødvendige antagelser for at OLS er:

	Eksakt (lille n)	Asymptotisk (stor n)
MLR.1-MLR.4	Middelret	Konsistent
MLR.1-MLR.4'	Biased	Konsistent
MLR.1-MLR.5	BLUE	Efficient Normalfordelt
MLR.1-MLR.6	Normalfordelt	