

Kvalitative variable (dummier)

Økonometri A

Bertel Schjerning

Program

Motivation (W7.1)

To kategorier (W7.2)

Mange kategorier (W7.3)

Interaktionseffekter (W7.4)

Chow-testet

Dummier som outcome variable (W7.5)

Den lineære sandsynlighedsmodel

Opsummering

Motivation

Indtil nu: Kontinuerte og kardinale variable

- Eksempler: Forbrug, priser, timeløn, uddannelse, erfaring, etc.
- Afstande mellem værdier er meningsfulde

Nu: Kategoriske og ordinale variable

- Køn (mand/kvinde)
- Sektor (offentlig/privat)
- Helbred (dårligt, middel, godt)
- Beskæftiget (i job/ikke i job)
- Bilmærke (Ford, Volvo, etc.), Motortype (El/Gas/Benzin/Hybrid)
- Udstyrsniveau (basis, mellemklasse, luksus)

Spørgsmål: Hvordan inkluderer vi dem i en regressionsmodel?

To kategorier

Dummyvariable

Kvalitativ information med to kategorier, fx biologisk køn (mand/kvinde) eller sektor (offentlig/privat), kan opsummeres i en **dummyvariabel**, som antager værdierne 0 og 1.

For eksempel:

$$kvinde_i = \begin{cases} 1 & \text{hvis person } i \text{ er en kvinde} \\ 0 & \text{ellers} \end{cases}$$

$$offentlig_i = \begin{cases} 1 & \text{hvis person } i \text{ er ansat i det offentlige} \\ 0 & \text{ellers} \end{cases}$$

Referencekategorien er den kategori, hvor variabelen er lig 0.

Dummyvariable kaldes også **indikatorvariable** eller **binære variable**.

Dummy variable i den simple regressionsmodel

Eksempel: Gender wage gap

$$\log(\text{timeløn}) = \beta_0 + \beta_1 \text{kvinde} + u, \quad E[u|\text{kvinde}] = 0$$

Fortolkning:

- For kvinder ($\text{kvinde} = 1$): $E(\log(\text{timeløn})|\text{kvinde} = 1) = \beta_0 + \beta_1$
- For mænd ($\text{kvinde} = 0$): $E(\log(\text{timeløn})|\text{kvinde} = 0) = \beta_0$

Forskel i forventet log-løn:

$$\beta_1 = E(\log(\text{timeløn})|\text{kvinde} = 1) - E(\log(\text{timeløn})|\text{kvinde} = 0)$$

For små $|\beta_1|$: procentvis forskel $\approx 100\beta_1$. Ofte er $\hat{\beta}_1 < 0$: kvinder tjener mindre i gennemsnit.

OLS-estimat for en dummyvariabel

OLS-estimat:

$$\begin{aligned}\hat{\beta}_1 &= \frac{\frac{1}{n} \sum_{i=1}^n y_i (x_i - \bar{x})}{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2} \\&= \frac{(1 - \bar{x})n_1 \bar{y}_{x=1} - \bar{x}n_0 \bar{y}_{x=0}}{n_1(1 - \bar{x})^2 + n_0 \bar{x}^2} = \frac{n\bar{x}(1 - \bar{x})(\bar{y}_{x=1} - \bar{y}_{x=0})}{n\bar{x}(1 - \bar{x})} \\&= \bar{y}_{x=1} - \bar{y}_{x=0}, \\ \hat{\beta}_0 &= \bar{y} - \hat{\beta}_1 \bar{x} = \bar{y}_{x=0}.\end{aligned}$$

hvor $n_1 = n\bar{x}$ og $n_0 = n(1 - \bar{x})$.

Fortolkning:

- $\hat{\beta}_0 = \bar{y}_{x=0}$: gennemsnitlig (log-) løn for mænd.
- $\hat{\beta}_1 = \bar{y}_{x=1} - \bar{y}_{x=0}$: forskel i gennemsnitlig (log-) løn mellem kvinder og mænd.
- Hvis $\hat{\beta}_1 < 0$, tjener kvinder i gennemsnit mindre end mænd.

Dummy variable i den multiple regressionsmodel

Model:

$$\log(\text{timeløn}) = \beta_0 + X\beta + \alpha \text{kvinde} + u,$$

hvor X indeholder uddannelse, erfaring, osv.

Antagelse: Under MLR.4:

$$E(u|X, \text{kvinde}) = 0 \implies$$


$$\alpha = E(\log(\text{timeløn})|X, \text{kvinde} = 1) - E(\log(\text{timeløn})|X, \text{kvinde} = 0)$$

α er forskellen i forventet log-løn mellem mænd og kvinder med samme X .

Bemærk: Modellen antager en konstant forskel i forventet log-løn. Interaktioner kan tillade, at forskellen afhænger af X .

Dummy variable i den multiple regressionsmodel

FIGURE 7.1 Graph of $wage = \beta_0 + \delta_0 \text{female} + \beta_1 \text{educ}$ for $\delta_0 < 0$.



Valg af referencegruppe

Hvad hvis vi i stedet havde inkluderet en dummy for “mand”?

Omskrivning af modellen:

$$mand_i + kvinde_i = 1 \quad \Longleftrightarrow \quad kvinde_i = 1 - mand_i$$

Resultat:

$$\begin{aligned}\log(\text{timeløn}) &= \beta_0 + \beta_1 \text{uddannelse} + \dots + \alpha \text{kvinde} + u \\ &= \beta_0 + \beta_1 \text{uddannelse} + \dots + \alpha(1 - \text{mand}_i) + u \\ &= (\beta_0 + \alpha) + \beta_1 \text{uddannelse} + \dots - \alpha \text{mand}_i + u\end{aligned}$$

Begge dummier kan ikke inkluderes sammen med konstantleddet—dette kaldes “**dummyfælden**”.



- **Jupyter Notebook:** `07_dummyvars_examples.ipynb`
- **Python Module:** `mymlr.py`
- **Part 1:** Lønforskelle mellem mænd og kvinder

Dummy variable i den multiple regressionsmodel

Dummy variable ændrer ikke OLS-egenskaber:

- **Gruppesammenligning:** Koefficienten på en dummy måler forskellen mellem grupperne, når de øvrige variable holdes faste. En kausal fortolkning kræver yderligere identifikationsantagelser.
- **Illustration:** En dummy giver et skift i konstantleddet, når de øvrige variable holdes faste.
- **Afhængig variabels form:**
 - **I niveau:** Absolut forskel mellem grupperne.
 - **I log:** Ca. 100α pct. forskel, når $|\alpha|$ er lille.

Regression med to dummyvariable

Med én dummy er OLS-estimatet forskellen i gennemsnit mellem to grupper.

Nu tilføjer vi en dummy for at arbejde i den offentlige sektor:

$$\log(\text{timeløn}) = \beta_0 + \beta_1 x + \beta_2 z + u,$$

hvor

- x : dummy for køn ($x = 1$ for kvinde, $x = 0$ for mand),
- z : dummy for sektor ($z = 1$ for offentlig, $z = 0$ for privat).

Ved Frisch–Waugh–Lovell kan vi vise, at

$$\hat{\beta}_1 = \frac{w_{z=1}(\bar{y}_{x=1,z=1} - \bar{y}_{x=0,z=1}) + w_{z=0}(\bar{y}_{x=1,z=0} - \bar{y}_{x=0,z=0})}{w_{z=1} + w_{z=0}}. \quad (1)$$

$\hat{\beta}_1$ er altså et vægtet gennemsnit af kønsforskellen *inden for* de to sektorer.

Vi kontrollerer dermed for sektor.

Regressionsmodel med to dummyvariable

OLS-estimatet er et *vægtet* gennemsnit af forskellen

....mellem kvinder ($x = 1$) og mænd ($x = 0$)

....i henholdsvis offentlig ($z = 1$) og privat sektor ($z = 0$):

$$\hat{\beta}_1 = \frac{w_{z=1}(\bar{y}_{x=1,z=1} - \bar{y}_{x=0,z=1}) + w_{z=0}(\bar{y}_{x=1,z=0} - \bar{y}_{x=0,z=0})}{w_{z=1} + w_{z=0}}$$

Vægtene er givet ved

$$w_{z=1} = \bar{z} \cdot \bar{x}_{z=1} \cdot (1 - \bar{x}_{z=1})$$

$$w_{z=0} = (1 - \bar{z}) \cdot \bar{x}_{z=0} \cdot (1 - \bar{x}_{z=0})$$

Dvs. vægtene er en funktion af to faktorer:

- Den relative størrelse af de to grupper ($\bar{z}$), og
- Den relative varians ($\bar{x}_z(1 - \bar{x}_z)$)

Hvorfor vægter OLS mere ved større varians?

OLS vægter de gruppespecifikke forskelle efter variationen i x inden for hver gruppe.

Hvorfor?

- Vægten er proportional med gruppens størrelse og $\text{Var}(x|z)$.
- **Højere varians:** Flere observationer med både $x = 0$ og $x = 1$ giver mere information og **større vægt**.
- **Lav varians:** Når x næsten er konstant, er der kun lidt information om effekten og dermed **mindre vægt**.

Mange kategorier

Kvalitative variable med mere end to kategorier

Kvalitative variable kan også antage flere end to niveauer. Fx uddannelse, branche eller region.

Hvis den kvalitative variabel har m kategorier:

- Konstrueres $m - 1$ dummyvariable, som antager værdien 0/1.
- Kategorien uden dummyvariabel kaldes **referencekategorien**.
- Medtages m dummyvariable, ender man i **dummyfælden**.
- Parameteren til dummyvariablen fortolkes som niveauforskellen til referencekategorien.
- Valget af referencekategorien:
 - har ingen betydning for modelegenskaberne,
 - men ændrer fortolkningen af parameterne

Dansk Branchekode DB07, v3:2014-

Navn: Dansk Branchekode DB07, v3:2014-

Beskrivelse:

Dansk Branchekode 2007 (DB07), er en 6-cifret branchenomenklatur, der først og fremmest er udarbejdet til statistisk brug. De indledende afsnit til DB07 beskriver regler og retningslinier for tildeling af branchekode til virksomhederne og deres produktionsenheder (arbejdssteder). Dermed sikres, at brancheplaceringen foretages på en ensartet måde i Danmarks Statistiks Erhvervsstatistiske Register (ESR) og dermed også i Det Centrale Virksomhedsregister (CVR).

DB07 er en dansk underopdeling af EU's fælles branchenomenklatur, den 4-cifrede NACE rev. 2. NACE rev. 2 er en revideret udgave af NACE rev. 1.1 fra 2002. NACE rev. 2 bygger på FN's branchenomenklatur ISIC rev. 4. NACE rev. 2 gælder fra 1. januar 2008 i alle EU-medlemstater ifølge forordning nr. 1893/2006.

Gyldig fra: 1. januar 2014

Kontor: Erhvervsindberetning og -registre

Kontaktperson: Birgit Nielsen, bgn@dst.dk, tlf. 39 17 38 69

Koder og kategorier

LUK HIERAKIET

DOWNLOAD ▾

- A: Landbrug, jagt, skovbrug og fiskeri
 - 01: Plante- og husdyravl, jagt og serviceydelser i forbindelse hermed
 - 01.1: Dyrkning af etårige afgrøder
 - 01.11: Dyrkning af korn (undtagen ris), bælgrugter og olieholdige frø
 - 011100: Dyrkning af korn (undtagen ris), bælgrugter og olieholdige frø
 - 01.12: Dyrkning af ris
 - 011200: Dyrkning af ris
 - 01.13: Dyrkning af grøntsager og meloner, rødder og rodknolde
 - 011300: Dyrkning af grøntsager og meloner, rødder og rodknolde
 - 01.14: Dyrkning af sukkerrør
 - 011400: Dyrkning af sukkerrør
 - 01.15: Dyrkning af tobak
 - 011500: Dyrkning af tobak

Kardinale variable som kategorier

Vi kan omforme kvalitative variable til dummier for at inkludere dem i vores estimationer.

Kardinale variable kan også omdannes til kategorier (eksempelvis uddannelse).

- **Fordele:** Mere fleksibel funktionel form.
- **Ulemper:** Flere variable $\rightarrow$
 - Øget varians af OLS estimaterne, da færre frihedsgrader gør estimaterne mindre præcise.
 - Beregning af $X'X$ og inversion af store matricer kræver mere CPU-tid og hukommelse.
 - For matricer større end 10000×10000 stiger beregningstiden og hukommelseskravene markant.

Mange moderne studier sammenligner estimater fra kardinale variable med dummykodede versioner.

Kardinal variable som kategorier: Eksempel

I stedet for at måle uddannelse i år, kunne vi også betragte det som en kategoriseret variabel:

- Minimum uddannelse ($\text{edu} < 10$).
- 10. klasse ($\text{edu}=10$).
- Ungdomsuddannelser ($\text{edu} \in [11; 13]$).
- Videregående uddannelser ($\text{edu} > 13$).

[Mere interessant kunne man også opdele i fagområde]

Variablen har 4 kategorier, så vi skal have 3 dummyvariable.

Regressionsmodel:

$$\begin{aligned}\log(\text{timeløn}) = & \beta_0 + \delta_1 \text{klasse10} + \delta_2 \text{ung.udd} + \delta_3 \text{videreg.udd} \\ & + \beta_2 \text{erfaring} + \beta_3 \text{erfaring}^2 + \beta_4 \text{kvinde} + u.\end{aligned}$$

Kardinal variable som kategorier: Eksempel

Hvordan kan vi teste hypotesen om at afkastet af uddannelse er lineært i antallet af års uddannelse?


To muligheder:

1. Test om sammenhængen mellem dummy estimerne er “linear” (se Wooldridge s. 230).
2. Inkl. den lineære effekt af uddannelse og test om dummy estimerne er 0.

Regressionsmodel:

$$\log(\text{timeløn}) = \beta_0 + \delta_1 \text{klasse10} + \delta_2 \text{ung.udd} + \delta_3 \text{videreg.udd} \\ + \beta_1 \text{uddannelse} + \beta_2 \text{erfaring} + \beta_3 \text{erfaring}^2 + \beta_4 \text{kvinde} + u.$$

Kardinal variable som kategorier: test for linearitet





- **Jupyter Notebook:** `07_dummyvars_examples.ipynb`
- **Python Module:** `mymlr.py`
- **Part 2:** Lønforskelle på tværs af uddannelseskategorier
- Specifikationstest (F-test: dummier eller lineær effekt)

Kardinale variable som kategorier: Eksempel

Boserup et al. (2018)¹ undersøger sammenhængen mellem forældre og børns formue

Dvs. en model a la:

$$\text{Børns formue} = \beta_0 + \beta_1 \text{Forældres formue} + u$$


Spørgsmålet er om vi kan antage at modellen er lineær? Løsning:

- Grupper forældrene i “formue ranks”, dvs. 100 lige store grupper efter formue og regresser

$$\text{Børns formue} = \beta_0 + \sum_j \beta_j \text{Forældres formue rank}_j + u$$

¹Kilde: Boserup, S.H., Kopczuk, W. and Kreiner, C.T. (2018), Born with a Silver Spoon? Danish Evidence on Wealth Inequality in Childhood. Econ J, 128

Kardinale variable som kategorier: Eksempel



Interaktionseffekte

Når vi inkluderer en dummyvariabel “for sig selv”, tillader vi **niveauskift** mellem to grupper.

Nogle gange vil vi også tillade forskelle i den marginale effekt af en anden variabel: **hældningsskift**.


Dette kan vi gøre ved at lave interaktionsled mellem variablene:

$$\log(\text{timeløn}) = \beta_0 + (\beta_1 + \beta_5 \text{kvinde}) \cdot \text{uddannelse} + \beta_2 \text{erfaring} \\ + \beta_3 \text{erfaring}^2 + \beta_4 \text{kvinde} + u$$

Bemærk at vi “altid” har niveauet med, når vi inkluderer interaktionsled.

Interaktionsled: Afkastet af uddannelse afhænger af køn

FIGURE 7.2 Graphs of equation (7.16): (a) $\delta_0 < 0$, $\delta_1 < 0$; (b) $\delta_0 < 0$, $\delta_1 > 0$.



Endelig kan vi interagere en dummyvariabel med en anden dummy

Derved tillader vi niveauskiftet mellem to gruppe varierer opdelt på to andre grupper:

Interaktionsled mellem single og køn:

$$\begin{aligned}\log(\text{timeløn}) = & \beta_0 + \beta_1 \text{uddannelse} + \beta_2 \text{erfaring} + \beta_3 \text{erfaring}^2 \\ & + \beta_4 \text{kvinde} + \beta_5 \text{single} + \beta_6 \text{single} \cdot \text{kvinde} + u.\end{aligned}$$

Implicit antal grupper?

4: Single mænd, single kvinder, gifte mænd og gifte kvinder.

Hvad er referencegruppen her?

Hvordan skal parameterne fortolkes?

$$\begin{aligned} E[\log(\textit{timeløn}) | \textit{erfaring}, \textit{uddannelse}, \textit{kvinde} = 1, \textit{single} = 1] - \\ E[\log(\textit{timeløn}) | \textit{erfaring}, \textit{uddannelse}, \textit{kvinde} = 0, \textit{single} = 0] = \end{aligned}$$

$$\textit{kvinde} = 1 \text{ og } \textit{single} = 0 \Rightarrow \beta_4$$

$$\textit{kvinde} = 0 \text{ og } \textit{single} = 1 \Rightarrow \beta_5$$

$$\textit{kvinde} = 1 \text{ og } \textit{single} = 1 \Rightarrow \beta_4 + \beta_5 + \beta_6$$



- **Jupyter Notebook:** `07_dummyvars_examples.ipynb`
- **Python Module:** `mymlr.py`
- **Part 3:** Interaktionseffekte

Quiz

Betragt den følgende regressionsmodel:

$$\log(\text{timeløn}) = \beta_0 + \beta_1 \text{uddannelse} + \beta_2 \text{erfaring} + \beta_3 \text{erfaring}^2 \\ \beta_4 \text{mand} + \beta_5 \text{børn} + \beta_6 \text{børn} \cdot \text{mand} + u.$$

Hvad er den forventede forskel mellem mænd med børn og kvinder med børn?

1. β_4
2. β_5
3. $\beta_4 + \beta_5$
4. $\beta_5 + \beta_6$
5. $\beta_4 + \beta_6$
6. $\beta_4 + \beta_5 + \beta_6$

Interaktionseffekter eller separate estimationer

Hvad hvis vi interagerer *alle* variable med en dummy?

Simpel model:

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + u$$

Interageret med en dummy d :

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \delta_0 d + \delta_1 x_1 \cdot d + \delta_2 x_2 \cdot d + u$$

Hvad er den betingede middelværdi af y for hver gruppe $d \in 0, 1$

$$\begin{aligned} E(y|d=0) &= \beta_0 && +\beta_1 x_1 && +\beta_2 x_2 \\ E(y|d=1) &= \beta_0 + \delta_0 && +(\beta_1 + \delta_1)x_1 && +(\beta_2 + \delta_2)x_2 \end{aligned}$$

Dvs. den betingede middelværdi i den interagerede model svarer til den betingede middelværdi fra to separate estimationer for de to grupper. 29

Interaktionseffekter eller separate estimationer

Separate modeller er typisk mere overskuelige. Både i forhold til at

- Præsentere regressionsmodellen.
- Fortolke parameterestimerne.

Men de gør det ikke umiddelbart muligt at teste om der er signifikante forskelle i parameterestimerne for grupperne.

Det kan vi gøre på to måder

- Kør den fuldt interagerede model og brug en standard F-test.
- Kør de to separate regressioner og brug **Chow-testet**.

Chow-testet med to grupper

Regressionsmodeller

$$y = \beta_{0,g} + \beta_{1,g}x_1 + \dots + \beta_{k,g}x_k \quad \text{for } g = 1, 2$$

$\Leftrightarrow$

$$y = \beta_0 + \beta_1x_1 + \dots + \beta_kx_k + \delta_0d_{g=2} + \delta_1x_1d_{g=2} + \dots + \delta_kx_kd_{g=2}$$

Modellerne har tilsammen $2(k + 1)$ parametre.

Hypotese for ingen forskel på grupperne:

$$H_0 : \beta_{0,1} = \beta_{0,2}, \beta_{1,1} = \beta_{1,2}, \dots, \beta_{k,1} = \beta_{k,2}$$

$$\Leftrightarrow \delta_0 = 0, \delta_1 = 0, \dots, \delta_k = 0$$

$$H_1 : H_0 \text{ ikke opfyldt.}$$

Chow-testet med to grupper

Procedure for Chow-testet

1. Estimer den samlede, restrikterede model og noter SSR_r .
2. Estimer modellen for gruppe 1 og noter SSR_1 .
3. Estimer modellen for gruppe 2 og noter SSR_2 .
4. Udregn teststørrelsen som

$$F = \frac{(SSR_r - SSR_{ur})/(k+1)}{SSR_{ur}/(n-2(k+1))}, \quad SSR_{ur} = SSR_1 + SSR_2.$$

5. Under H_0 er teststørrelsen F -fordelt med $(k+1)$ og $(n-2(k+1))$ frihedsgrader.

OBS. Chow-testet antager samme fejlvarians i de to grupper.

Chow-testet som en almindelig F-test

Husk at $SSR = \sum_{i=1}^n (y_i - \hat{y}_i)^2$.

Med to grupper kan vi skrive SSR for den fuldt interagerede model som

$$SSR_{ur} = \sum_{i:g_i=1} (y_i - \hat{y}_i)^2 + \sum_{i:g_i=2} (y_i - \hat{y}_i)^2$$

Da $\hat{y}_i$ er de samme som ved separate regressioner, er

$$SSR_{ur} = SSR_1 + SSR_2.$$

Dermed er Chow-teststørrelsen

$$F = \frac{(SSR_r - SSR_{ur})/(k+1)}{SSR_{ur}/(n-2(k+1))}.$$

Det er det almindelige F-test, som sammenligner den samlede restrikerede model med den fuldt interagerede model.



- **Jupyter Notebook:** `07_dummyvars_examples.ipynb`
- **Python Module:** `mymlr.py`
- **Part 4:** Chow-test med to grupper
- Fuldt interageret model og separate regressioner
- Beregning af Chow-teststørrelsen

Chow-testet med flere end to grupper

Chow-testet kan udvides til mere end to grupper:

Procedure

1. Estimer den samlede, restriktede model og noter SSR_r .
2. Estimer modellen for hver gruppe g og noter SSR_g .
3. Udregn teststørrelsen som

$$F = \frac{(SSR_r - \sum_g SSR_g)/((G - 1)(k + 1))}{(\sum_g SSR_g)/(n - G(k + 1))}.$$

4. Under H_0 er teststørrelsen F -fordelt med $(G - 1)(k + 1)$ og $(n - G(k + 1))$ frihedsgrader.

Dummier som outcome variable

Dummier som outcome variable

Indtil nu har vi set på modeller, hvor den afhængige variabel er kontinuert (f.eks. løn, forbrug, test score, BNP).

Hvad hvis den afhængige variabel er binær (antager to værdier)?

Eksempler:

- Arbejde eller ikke arbejde.
- Selvstændig eller lønmodtager.
- Består eksamen i økonometri A eller ej.
- Købe en bil eller ikke købe en bil.
- Investere i aktier eller ej.
- Blive skilt eller ej.
- Virksomheder eksporterer eller ej.
- Får et barn eller ej.
- Tag et SU lån, så man kan tage med DatØk på skiferie.

Den lineære sandsynlighedsmodel

Antag at y kun tager værdierne 0 eller 1.

Regressionsmodellen er nu (som den plejer):

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_k x_k + u$$

$$E(y|x) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_k x_k$$

Da y er binær gælder der, at

$$E(y|x) = \Pr(y = 0|x) \cdot 0 + \Pr(y = 1|x) \cdot 1 = \Pr(y = 1|x).$$

Dvs. at vi har lavet en model for sandsynligheden

$$\Pr(y = 1|x) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_k x_k.$$

Den lineære sandsynlighedsmodel

Modellen kaldes den **lineære sandsynlighedsmodel**.

$$\Pr(y = 1|x) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_k x_k.$$

Vi kan også udregne sandsynligheden for at $y = 0$

$$\Pr(y = 0|x) = 1 - \Pr(y = 1|x) = 1 - \beta_0 - \beta_1 x_1 - \beta_2 x_2 - \dots - \beta_k x_k.$$

Den lineære sandsynlighedsmodel

Fortolkningen af parametrene:

$$\Delta \Pr(y = 1|x) = \beta_j \Delta x_j.$$

Fortolkning af β_j :

- y er diskret, så man kan ikke tale om en marginal ændring i y som følge af en ændring i x på en enhed.
- β angiver ændringen i sandsynligheden for $y = 1$ som følge af en ændring i x på en enhed.

Under MLR.1–MLR.4 er OLS fortsat middelret. Standardfejlene skal dog korrigeres for heteroskedasticitet.

Den lineære sandsynlighedsmodel

Ulemper ved den lineære sandsynlighedsmodel:

- De prædikterede værdier af y ligger ikke nødvendigvis i intervallet $[0, 1]$.
- Dvs. de prædikterede sandsynligheder kan være mindre end 0 eller større end 1.
- Den lineære funktion kan desuden være en dårlig approksimation, når sandsynligheden er tæt på 0 eller 1.

Gauss-Markow antagelserne:

- MLR.1–MLR.4 kan være opfyldt. Det må som altid vurderes i det konkrete tilfælde.
- MLR.5 er per definition **ikke opfyldt**: brug heteroskedasticitetsrobuste standardfejl.

Variansen i den lineære sandsynlighedsmodel

Da y er binær, kan u kun antage to værdier for givet x :

$$y = 1 \Rightarrow u = 1 - \beta_0 - \beta_1 x_1 - \cdots - \beta_k x_k = 1 - p(x)$$

$$y = 0 \Rightarrow u = -\beta_0 - \beta_1 x_1 - \cdots - \beta_k x_k = -p(x)$$

Variansen af u for givet x :

$$\begin{aligned}\text{Var}(u|x) &= E(u^2|x) \\ &= E(u^2|x, y = 1)p(x) + E(u^2|x, y = 0)(1 - p(x)) \\ &= (1 - p(x))^2 p(x) + (-p(x))^2 (1 - p(x)) \\ &= (1 - p(x))p(x)[(1 - p(x)) + p(x)] \\ &= (1 - p(x))p(x)\end{aligned}$$

Da $\text{Var}(u|x)$ afhænger af $x \Rightarrow$ heteroskedasticitet.

Simple lineære sandsynlighedsmodel

Quiz: Antag, at vi har følgende model, hvor d og y er dummyvariable

$$y = \beta_0 + \beta_1 d + u$$

Vi har 100 observationer som fordeler sig således

	$d = 0$	$d = 1$
$y = 0$	20	40
$y = 1$	20	20

A: Hvad er estimatet af β_0 ?

a1. $\hat{\beta}_0 = \frac{1}{4}$

a2. $\hat{\beta}_0 = \frac{1}{2}$

a3. $\hat{\beta}_0 = \frac{2}{3}$

B: Hvilket fortegn vil $\hat{\beta}_1$ være?

b1. $\hat{\beta}_1 > 0$

b2. $\hat{\beta}_1 = 0$

b3. $\hat{\beta}_1 < 0$

Udregn OLS estimatoren for β_1

Den lineære sandsynlighedsmodel: Eksempel

Vi ønsker at modellere sandsynligheden for at blive arresteret

$$arr86 = \beta_0 + \beta_1 pcnv + \beta_2 avg\text{sen} + \beta_3 tot\text{time} + \beta_4 pt\text{time}86 + \beta_5 qemp86 + u$$

hvor

<i>arr86</i>	Arresteret i 1986 (binær variabel)
<i>pcnv</i>	Andel af tidligere arrestationer, som medførte dom
<i>avg\text{sen}</i>	Gennemsnitlig længde af tidligere straffe
<i>tot\text{time}</i>	Total tid i fængsel siden 18 års alderen
<i>pt\text{time}86</i>	Måneder i fængsel i 1986
<i>qemp86</i>	Antal kvartaler i beskæftigelse i 1986

Population: Mænd i Californien født 1960-61 og som mindst en gang før 1986 har været arresteret.



- **Jupyter Notebook:** `07_dummyvars_examples.ipynb`
- **Python Module:** `mymlr.py`
- **Part 5:** Den lineære sandsynlighedsmodel
- Sandsynligheden for at blive arresteret
- Forudsagte sandsynligheder og heteroskedasticitet

Outcome variable med flere end to kategorier

Hvad gør vi, hvis outcome-variablen har mere end to kategorier? Fx

- Arbejdsløs, Studerende, Beskæftiget.

En løsning er at danne to dummier, fx

- $D_1 = 1$ hvis studerende og 0 ellers.
- $D_2 = 1$ hvis beskæftiget og 0 ellers.

Man kan som en simpel beskrivende analyse køre en separat LPM for hver dummy.

De separate modeller sikrer dog ikke, at sandsynlighederne ligger i $[0, 1]$ eller summerer til 1. Multinomiale modeller behandles i Økonometri B.

Opsummering

- Dummy variable gør det muligt at arbejde med kvalitativ information i OLS modeller.
- Dummier ændrer ikke grundlæggende på OLS egenskaberne.
- Dummier for sig selv tillader niveauforskelle mellem grupper (level shifts).
- Interaktionsled tillader forskelle i hældning mellem grupper (slope shifts)
- Variable med flere end 2 kategorier kan omdannes til flere (0/1)-dummyvariable.
- En dummy, som outcome variabel, medfører den lineære sandsynlighedsmodel.