

Proxyvariable, målefejl og manglende data

Økonometri A

Bertel Schjerning

Proxyvariable (W9.2)

Målefejl (W9.4)

- Målefejl i den afhængige variabel

- Målefejl i forklarende variable

Dataproblemer (W9.5)

- Manglende observationer

- Dataudvælgelse

- Ekstreme observationer

Motivation

Nogle gange har vi ikke præcis de variable, vi kunne ønske os.

Fx hvis vi

- Skal estimere effekten af skat på arbejdsudbuddet, skal vi kende folks marginalskat.
- Ønsker at kontrollere for “evne” i regressionen af løn på uddannelse.
- Bruger surveydata, hvor folk selv har skullet oplyse formue mv.

Overordnet skelner vi mellem:

- **Proxyvariable:** Proxy for en uobserveret variabel, som **ikke har en præcis kvantitativ fortolkning**.
 - Fx helbred eller evner, som kan være svære at kvantificere.
 - Vi er ofte ikke interesserede i effekten af variabelen, men ønsker at kontrollere for den.
- **Målefejl:** Variable opgjort med målefejl, som har en **præcis kvantitativ fortolkning**.
 - Fx har forbrug en præcis betydning, men selvrapporterede forbrugsudgifter kan være målt med fejl.
 - Folk husker forkert eller har glemt indkøb.
 - Vi er ofte interesserede i parameteren til variabelen.

Proxyvariable

Antag at den sande model er givet ved

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2^* + u \quad (1)$$

hvor vi er interesserede i β_1 . x_2^* er således kun med i modellen for at den opfylder MLR.1-MLR.4. Det antager vi her.

x_2^* **er dog uobserveret.**

I stedet observerer vi en proxy x_2 , som er korreleret med x_2^* :

$$x_2^* = \delta_0 + \delta_1 x_2 + v, \text{ med } \delta_1 \neq 0 \quad (2)$$

Spørgsmålet er nu, om vi kan få et middelret estimat ved at inkludere x_2 i stedet for x_2^* .

Hvis vi indsætter ligning (2) i ligning (1) får vi

$$\begin{aligned}y &= \beta_0 + \beta_1 x_1 + \beta_2(\delta_0 + \delta_1 x_2 + v) + u \\&= \beta_0 + \beta_2 \cdot \delta_0 + \beta_1 x_1 + \beta_2 \delta_1 x_2 + u + \beta_2 v \\&= \tilde{\beta}_0 + \beta_1 x_1 + \tilde{\beta}_2 x_2 + e\end{aligned}$$

Vi kan få et middelret estimat af β_1 , hvis det nye fejllid opfylder MLR.4:

$$E(e|x_1, x_2) = E(u + \beta_2 v|x_1, x_2) = 0.$$

Et tilstrækkeligt, men ikke automatisk opfyldt, sæt betingelser er

$$E(u|x_1, x_2) = 0 \quad \text{og} \quad E(v|x_1, x_2) = 0.$$

Proxyvariable: Eksempel

Antag at MLR.1-MLR.4 er opfyldt for den følgende model

$$\log(\text{løn}) = \beta_0 + \beta_1 \text{uddannelse} + \beta_2 \text{evner} + u \quad (3)$$

Vi observerer ikke folks sande evner, men vi kan observere

$$\text{evner} = \delta_0 + \delta_1 IQ + v \quad (4)$$

OLS-estimation af (3) med IQ som proxy for evner er middelret, hvis

$$E(u + \beta_2 v | \text{uddannelse}, IQ) = 0. \quad (5)$$

Er det en rimelig antagelse?

Blandt personer med samme IQ kan uddannelse stadig hænge sammen med fx motivation, selvdisciplin og familiebaggrund.

Bias uden proxy

Vi kan sammenligne den asymptotiske bias ved helt at undlade x_2^* og ved at anvende en proxy.

Bias ved undladelse

$$\text{plim } \hat{\beta}_1^u - \beta_1 = \beta_2 \frac{\text{cov}(x_1, x_2^*)}{\text{var}(x_1)} = \beta_2 \frac{\delta_1 \text{cov}(x_1, x_2) + \text{cov}(x_1, v)}{\text{var}(x_1)}$$

Uden proxy ligger hele x_2^* i fejlleddet. Både den del, som x_2 opfanger, og den resterende del v kan derfor skabe bias.

Bias med proxy

Lad r_1 være residualet fra populationsprojektionen af x_1 på et konstantled og x_2 . FWL giver

$$plim \hat{\beta}_1^m - \beta_1 = \frac{\text{cov}(r_1, u + \beta_2 v)}{\text{var}(r_1)}.$$

Hvis $\text{cov}(r_1, u) = 0$, kommer den resterende bias fra den del v , som proxyen ikke opfanger:

$$plim \hat{\beta}_1^m - \beta_1 = \beta_2 \frac{\text{cov}(r_1, v)}{\text{var}(r_1)}.$$

En proxy kan derfor reducere bias, men det er ikke garanteret.

Målefejl

Målefejl i den afhængige variabel

Antag at vi har følgende model

$$y^* = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_k x_k + u,$$

hvor MLR.1-MLR.4 er opfyldt.

- y^* er **uobserveret**.
- I stedet observerer vi $y = y^* + e$
- e er en målefejl: $e = y - y^*$.

Hvad er konsekvensen ved at anvende y i stedet for y^* ?

Estimationsmodel

$$y = y^* + e = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_k x_k + u + e$$

Målefejl i den afhængige variabel

Vil OLS-estimatoren være middelfret og konsistent?

Det kræver, at der for det nye fejllid $u + e$ gælder:

$$\begin{aligned} E(u + e|X) &= E(u|X) + E(e|X) \\ &= 0 + E(e|X) = 0. \end{aligned}$$

- Det er nok, at $E(e|X)$ er konstant: Konstantleddet absorberer middelværdien.
- Antagelsen $E(e|X) = 0$ gælder fx, hvis e er uafhængig af $x_1, x_2, \dots, x_k$.
- Så vil **OLS-estimatoren** i en model med målefejl i den afhængige variabel stadig være **middelfret og konsistent**.

Målefejl i den afhængige variabel

Er $E(e|X) = 0$ en realistisk antagelse?

- Ofte ja.
- Men ikke altid.
- Hvis rige underrapporterer deres indkomst/formue.

Målefejl i den afhængige variabel

Hvad med variansen på OLS-estimatoren?

- Hvis u og e er ukorrelerede og homoskedastiske, får vi

$$\text{var}(u + e|X) = \sigma_u^2 + \sigma_e^2 > \sigma_u^2.$$

Dvs. større varians af fejleddet, hvis der er målefejl i den afhængige variabel.

→ Større varians på parameterestimatoren $\text{var}(\hat{\beta}_j|X)$ og mindre præcision.

Multiplikative målefejl

Nogle gange giver det mere mening at antage, at målefejlen er multiplikativ.

- Fx hvis størrelsen af målefejlene er proportional med y -variablen.
- Afhængig variabel:

$$y = y^* \cdot a, \quad a > 0$$

Logaritmen gør målefejlen additiv:

$$\begin{aligned}\log(y) &= \log(y^*) + \log(a) \\ &= \log(y^*) + e,\end{aligned}$$

hvor $e = \log(a)$.

Dvs. vi er tilbage i setuppet fra før. Men logaritmen løser kun problemet, hvis $E(\log(a)|X)$ er konstant.

Målefejl i forklarende variable

Vi betragter igen den sande model

$$y = \beta_0 + \beta_1 x^* + u,$$

hvor MLR.1-MLR.4 er opfyldt.

- x^* er ikke observeret.
- Forholdet mellem x^* og det observerede x bestemmer konsekvensen.

To tilfælde:

1. $x^* = x + e$ og $E(e|x) = 0$: Berkson-målefejl.
2. $x = x^* + e$ og $\text{cov}(e, x^*) = 0$: Klassisk målefejl.

Tilfælde 1: Berkson-målefejl

Indsæt $x^* = x + e$ i modellen:

$$\begin{aligned}y &= \beta_0 + \beta_1 x^* && + u \\&= \beta_0 + \beta_1 (x + e) && + u \\&= \beta_0 + \beta_1 x && + u + \beta_1 e.\end{aligned}$$

Hvis $E(u|x) = 0$ og $E(e|x) = 0$, er det nye fejllad middelret:

$$E(u + \beta_1 e|x) = 0.$$

Derfor er OLS middelret og konsistent. Berkson-målefejl opstår fx, når alle i en gruppe tildeles samme mål, mens deres sande værdier varierer omkring gruppemålet.

Tilfælde 2: Klassisk målefejl

Indsæt igen $x^* = x - e$ i modellen

$$y = \beta_0 + \beta_1 x + u - \beta_1 e.$$

Antag $\text{cov}(u, x^*) = \text{cov}(u, e) = \text{cov}(e, x^*) = 0$. For det nye fejllid gælder:

$$\begin{aligned}\text{cov}(u - \beta_1 e, x) &= \text{cov}(u - \beta_1 e, x^* + e) \\ &= -\beta_1 \text{var}(e) = -\beta_1 \sigma_e^2.\end{aligned}$$

Det observerede x er derfor korreleret med det nye fejllid.

Tilfælde 2: Klassisk målefejl

Den asymptotiske bias af $\hat{\beta}_1$ er nu

$$\begin{aligned} p \lim \hat{\beta}_1 - \beta_1 &= \frac{\text{cov}(u - \beta_1 e, x)}{\text{var}(x)} \\ &= -\beta_1 \frac{\sigma_e^2}{\text{var}(x^* + e)} \\ &= -\beta_1 \frac{\sigma_e^2}{\sigma_{x^*}^2 + \sigma_e^2} \end{aligned}$$

Dermed er sandsynlighedsgrænsen

$$p \lim \hat{\beta}_1 = \beta_1 \frac{\sigma_{x^*}^2}{\sigma_{x^*}^2 + \sigma_e^2}.$$

Tilfælde 2: Klassisk målefejl

Konklusion: OLS-estimatoren er inkonsistent og attenueret mod nul, da

$$0 < \frac{\sigma_{x^*}^2}{\sigma_{x^*}^2 + \sigma_e^2} < 1$$

- Hvis $\beta_1 > 0$ så er $p \lim \hat{\beta}_1 < \beta_1$
- Hvis $\beta_1 < 0$ så er $p \lim \hat{\beta}_1 > \beta_1$
- Jo større målefejlsvariansen er, jo større er den asymptotiske bias.

Dette kalder vi typisk for **attenuation bias**.

For flere forklarende variable bliver det mere kompliceret.

- Målefejl i én regressor kan generelt påvirke flere koefficienter, og retningen er ikke nødvendigvis mod nul.

Tilfælde 2: Klassisk målefejl

Quiz

Sand model

$$y = 1 + 2x^* + u$$

$$x = x^* + e$$

hvor

- $\text{cov}(e, x^*) = 0$ (klassisk målefejl)
- $x^* \sim N(2, 1)$, $u \sim N(0, 1)$, $e \sim N(0, 1)$

Estimationsmodel

$$y = \beta_0 + \beta_1 x + v$$

Hvad er sandsynlighedsgrænsen for OLS-estimatoren $\hat{\beta}_1$?

Monte Carlo Simulation

Den sande model

$$y = \beta_0 + \beta_1 x^* + u.$$


Setup og antagelser:

- Antallet af replikationer 1000
- Antallet af observationer $n = 100$
- $x = x^* + e$
- $\text{cov}(e, x^*) = 0$ (klassisk målefejl).
- Parametre: $\beta_0 = 1, \beta_1 = 2$.
- Fordelingen: $x^* \sim N(2, 1), u \sim N(0, 1), e \sim N(0, 1)$

Regressionsmodel


$$y = \beta_0 + \beta_1 x + v$$

Monte Carlo: $\text{var}(e) = 1$



$\hat{\beta}_1$ er centreret omkring $2 \cdot 1/(1 + 1) = 1$.

Monte Carlo: $\text{var}(e) = 0.5$



$\hat{\beta}_1$ er centreret omkring $2 \cdot 1/(1 + 0.5) = 4/3$.



- **Jupyter Notebook:** `11_simulation_examples.ipynb`
- **Part 1:** Målefejl i den forklarende variabel
- Eksperimenter med attenuation bias og målefejlsvarians

Dataproblemer

Indtil nu har vi antaget, at **MLR.2** er opfyldt:

- MLR.2: Observationerne (y_i, X_i) er uafhængige og identisk fordelte træk fra populationen.

Det er ikke altid tilfældet:

- Manglende observationer: tilfældigt eller ikke tilfældigt
- Dataudvælgelse: endogen eller eksogen udvælgelse
- Korrelerede fejllid (kun delvist dækket i Wooldridge)

Derudover skal vi snakke kort om problemer med

- Ekstreme observationer

Manglende observationer

Manglende observationer for en eller flere af variablene.

Er det et problem?

- Ud over at manglende observationer reducerer n .

Det er vigtigt at vide, hvorfor observationerne mangler.

- Lad $s = 1$ betyde, at observationen indgår i stikprøven. Den centrale betingelse er

$$E(u|X, s = 1) = 0.$$

- Observationer må gerne mangle afhængigt af X , hvis denne betingelse fortsat holder.

Hvis $E(u|X, s = 1) = 0$, er OLS stadig **middelret og konsistent** i den observerede stikprøve.

Hvornår er manglende observationer et problem?

Problemet opstår, når selektionen ændrer fejlleddets betingede middelværdi:

$$E(u|X, s = 1) \neq 0.$$

Eksempler:

- Kun studerende, som er ekstraordinært glade eller sure, svarer på evalueringerne.
- Kun særligt dygtige lavtuddannede tager en IQ-test.

Det er altså ikke manglende observationer i sig selv, men **årsagen til, at de mangler**, som er afgørende.

Opgave om manglende observationer

Vi skal se på, hvordan manglende observationer kan påvirke estimationen ved hjælp af et simulationseksperiment.

Til simulationseksperimentet bruger vi, at

$$x \sim N(2, 1), v \sim U(0, 1), e \sim N(0, 1),$$

Ud fra disse variable danner vi u , y og s :

$$u = e + 2(v - 0.5),$$

$$s = 1(v > 0.2),$$

$$y = 1 + x + u.$$

Den sande model er $y = 1 + x + u$, men vi observerer kun y , når $s = 1$.

Opgave om manglende observationer

Vi bruger simulationen til at besvare følgende spørgsmål:

- Estimer modellen, hvor alle observationer bruges. Er OLS estimatoren for β_0 og β_1 middelret og konsistent?
- Estimer modellen, hvor der kun anvendes observationer hvor $s = 1$. Er OLS-estimatoren for β_0 og β_1 middelret og konsistent?
- Hvilke aspekter af modellen er kritiske for resultaterne?

Monte Carlo med $n = 500$ og 1.000 replikationer:

Stikprøve	Parameter	Sand værdi	Gns. estimat
Alle observationer	β_0	1	1.000
	β_1	1	1.000
Kun $s = 1$	β_0	1	1.201
	β_1	1	1.000

- Med alle observationer er begge estimatorer middelrette.
- Når kun $s = 1$ observeres, ændres konstantleddet, men ikke hældningen.

Hvorfor ændres kun konstantleddet?

Når $s = 1$, ved vi, at $v > 0.2$. Derfor

$$E(v|s = 1) = 0.6,$$

$$E(u|s = 1) = E(e) + 2\{E(v|s = 1) - 0.5\} = 0.2.$$

Da x er uafhængig af selektionen,

$$E(u|x, s = 1) = 0.2.$$

Regressionen i den observerede stikprøve er derfor

$$y = 1.2 + x + \underbrace{(u - 0.2)}_{\text{betinget middelværdi 0}}.$$

Selektionen flytter konstantleddet, men ikke hældningen.

Nogle gange er det os som økonometrikere, som udvælger data baseret på forskellige karakteristika (fx alder).

Her skelner vi mellem

- **Eksogen dataudvælgelse:** baseret på forklarende variable.
- **Endogen dataudvælgelse:** baseret på den afhængige variabel.
- **Stratificerede data:** Oversampling af observationer med givne forklarende variable.

Nogle gange kommer vi til at udvælge data uden eksplicit at tænke over det.

Som ved manglende observation, medfører ikke alle typer dataudvælgelse bias.

Dataudvælgelse: Eksogen

Eksogen dataudvælgelse er baseret på en eller flere af de forklarende variable.


- Det er i udgangspunktet ikke et problem.
- Hvis $E(y|x)$ er den samme korrekt specificerede funktion i hele populationen, estimerer vi den samme populationskoefficient i forskellige intervaller af x .
- I så fald er OLS-estimatoren stadig middelret og konsistent.

Hvis den funktionelle form er forkert, kan estimerterne ændre sig på tværs af stikprøver.

- Det er ikke nødvendigvis et problem. Tværtimod kan det være nyttig information.


Stratificering er et eksempel på eksogen dataudvælgelse.

Hele stikprøven



Den estimerede linje beskriver den betingede sammenhæng i hele stikprøven.

Eksogen udvælgelse: $x > 5$



Ved en korrekt lineær model ændrer udvælgelse på x ikke populationshældningen.

Dataudvælgelse: Endogen

Endogen dataudvælgelse er baseret på den afhængige variabel - enten eksplicit eller implicit.

Eksempler

- **Effekten af uddannelse på lønnen blandt lavtlønnede**

Uddannelse reducerer sandsynligheden for at være lavt lønnet.

Vi ender med en stikprøve af alle lavtuddannede og de dårligst lønnede højtuddannede.


- **Effekten af uddannelse på timelønnen**

Vi observerer kun timelønnen for personer i arbejde.

Der kan være systematiske forskelle på personer i arbejde og personer, som ikke arbejder.

OLS-estimatoren vil generelt **ikke** være **middelret og konsistent**, fordi $E(u|X, s = 1) \neq 0$.

Endogen udvælgelse: $y < 15$



Udvælgelse på y ændrer typisk $E(u|x, s = 1)$ og dermed den estimerede hældning.

Stikprøveudvælgelse: Hvad skal vi huske?

Selektionsmekanisme	Konsekvens
Tilfældig eller kun baseret på inkluderede X	$E(u X, s = 1) = 0$: Den oprindelige regressionsfunktion bevarer.
Baseret på u , men uafhængig af X	$E(u X, s = 1)$ kan være konstant: Konstantleddet ændres, mens hældningerne kan bevares.
Baseret på både X og u — eller direkte på y	$E(u X, s = 1)$ varierer typisk med X : Hældningerne bliver generelt biased.

Det afgørende er altså ikke blot, om der er selektion, men hvordan selektionen ændrer $E(u|X, s = 1)$.



- **Jupyter Notebook:** `11_simulation_examples.ipynb`
- **Part 2A:** Eksemplet fra slides
- **Part 2B:** Eksperimenter med forskellige selektionsmekanismer

Ekstreme observationer

Ekstreme observationer er observationer, som skiller sig ud relativt til resten af stikprøven.

Ekstreme observationer kan have stor betydning for OLS-estimerne.

- En **outlier** har et stort residual.
- En observation med **høj leverage** har ekstreme værdier af de forklarende variable.
- En **indflydelsesrig observation** ændrer estimerne mærkbart.

Hvorfor optræder der ekstreme observationer?

- Datafejl fx indtastningsfejl.
- Databehandling, fx beregning af timeløn for personer med meget få timer.
- Nogle observationer er reelt ekstreme, fx meget store virksomheder eller meget høje indkomster.

Hvad skal vi gøre med ekstreme observationer?

- Kontrollér først, om observationen skyldes en datafejl, og ret fejlen ved kilden.
- Estimer med og uden de ekstreme observationer og se hvor stor forskel det gør.
- Brug kun transformationer, fx logaritmer, når de er økonomisk og statistisk meningsfulde.
- Der findes estimatorer, som er mindre følsomme over for ekstreme observationer.

Opsummering

- En proxyvariabel kan reducere bias og i visse tilfælde genskabe middelretheden af OLS.
- Ikke-differentiel målefejl i den afhængige variabel giver typisk mindre præcise OLS-estimer.
- Klassisk målefejl i en enkelt forklarende variabel giver attenuation mod nul i simpel regression.
- Ved manglende observationer er den centrale betingelse $E(u|X, s = 1) = 0$.
- Dataudvælgelse på X , inkl. stratificering, er typisk uproblematisk for en korrekt specificeret regressionsmodel.
- Udvalgelse på y medfører typisk $E(u|X, s = 1) \neq 0$ og dermed bias.