

Proxyvariable, målefejl og manglende data

Økonometri A

Bertel Schjerning

Proxyvariable (W9.2)

Målefejl (W9.4)

- Målefejl i den afhængige variabel

- Målefejl i forklarende variable

Dataproblemer (W9.5)

- Stikprøveudvælgelse

- Ekstreme observationer

Motivation

Nogle gange har vi ikke præcis de variable, vi kunne ønske os.

Fx hvis vi

- Skal estimere effekten af skat på arbejdsudbuddet, skal vi kende folks marginalskat.
- Ønsker at kontrollere for “evne” i regressionen af løn på uddannelse.
- Bruger surveydata, hvor folk selv har skullet oplyse formue mv.

Overordnet skelner vi mellem:

- **Proxyvariable:** Proxy for en uobserveret variabel, som **ikke har en præcis kvantitativ fortolkning**.
 - Fx helbred eller evner, som kan være svære at kvantificere.
 - Vi er ofte ikke interesserede i effekten af variabelen, men ønsker at kontrollere for den.
- **Målefejl:** Variable opgjort med målefejl, som har en **præcis kvantitativ fortolkning**.
 - Fx har forbrug en præcis betydning, men selvrapporterede forbrugsudgifter kan være målt med fejl.
 - Folk husker forkert eller har glemt indkøb.
 - Vi er ofte interesserede i parameteren til variabelen.

Proxyvariable

Antag at den sande model er givet ved

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2^* + u \quad (1)$$

hvor vi er interesserede i β_1 . x_2^* er således kun med i modellen for at den opfylder MLR.1-MLR.4. Det antager vi her.

x_2^* **er dog uobserveret.**

I stedet observerer vi en proxy x_2 , som er korreleret med x_2^* :

$$x_2^* = \delta_0 + \delta_1 x_2 + v, \text{ med } \delta_1 \neq 0 \quad (2)$$

Spørgsmålet er nu, om vi kan få et middelret estimat ved at inkludere x_2 i stedet for x_2^* .

Hvis vi indsætter ligning (2) i ligning (1) får vi

$$\begin{aligned}y &= \beta_0 + \beta_1 x_1 + \beta_2(\delta_0 + \delta_1 x_2 + v) + u \\&= \beta_0 + \beta_2 \cdot \delta_0 + \beta_1 x_1 + \beta_2 \delta_1 x_2 + u + \beta_2 v \\&= \tilde{\beta}_0 + \beta_1 x_1 + \tilde{\beta}_2 x_2 + e\end{aligned}$$

Vi kan få et middelret estimat af β_1 , hvis det nye fejllid opfylder MLR.4:

$$E(e|x_1, x_2) = E(u + \beta_2 v|x_1, x_2) = 0.$$

Et tilstrækkeligt, men ikke automatisk opfyldt, sæt betingelser er

$$E(u|x_1, x_2) = 0 \quad \text{og} \quad E(v|x_1, x_2) = 0.$$

Proxyvariable: Eksempel

Antag at MLR.1-MLR.4 er opfyldt for den følgende model

$$\log(\text{løn}) = \beta_0 + \beta_1 \text{uddannelse} + \beta_2 \text{evner} + u \quad (3)$$

Vi observerer ikke folks sande evner, men vi kan observere

$$\text{evner} = \delta_0 + \delta_1 IQ + v \quad (4)$$

OLS-estimation af (3) med IQ som proxy for evner er middelret, hvis

$$E(u + \beta_2 v | \text{uddannelse}, IQ) = 0. \quad (5)$$

Er det en rimelig antagelse?

Blandt personer med samme IQ kan uddannelse stadig hænge sammen med fx motivation, selvdisciplin og familiebaggrund.

Bias uden proxy

Vi kan sammenligne den asymptotiske bias ved helt at undlade x_2^* og ved at anvende en proxy.

Bias ved undladelse

$$\text{plim } \hat{\beta}_1^u - \beta_1 = \beta_2 \frac{\text{cov}(x_1, x_2^*)}{\text{var}(x_1)} = \beta_2 \frac{\delta_1 \text{cov}(x_1, x_2) + \text{cov}(x_1, v)}{\text{var}(x_1)}$$

Uden proxy ligger hele x_2^* i fejlleddet. Både den del, som x_2 opfanger, og den resterende del v kan derfor skabe bias.

Bias med proxy

Lad r_1 være residualet fra populationsprojektionen af x_1 på et konstantled og x_2 . FWL giver

$$plim \hat{\beta}_1^m - \beta_1 = \frac{\text{cov}(r_1, u + \beta_2 v)}{\text{var}(r_1)}.$$

Hvis $\text{cov}(r_1, u) = 0$, kommer den resterende bias fra den del v , som proxyen ikke opfanger:

$$plim \hat{\beta}_1^m - \beta_1 = \beta_2 \frac{\text{cov}(r_1, v)}{\text{var}(r_1)}.$$

En proxy kan derfor reducere bias, men det er ikke garanteret.

Målefejl

Målefejl i den afhængige variabel

Antag at vi har følgende model

$$y^* = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_k x_k + u,$$

hvor MLR.1-MLR.4 er opfyldt.

- y^* er **uobserveret**.
- I stedet observerer vi $y = y^* + e$
- e er en målefejl: $e = y - y^*$.

Hvad er konsekvensen ved at anvende y i stedet for y^* ?

Estimationsmodel

$$y = y^* + e = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_k x_k + u + e$$

Målefejl i den afhængige variabel

Vil OLS-estimatoren være middelfret og konsistent?

Det kræver, at der for det nye fejllid $u + e$ gælder:

$$\begin{aligned} E(u + e|X) &= E(u|X) + E(e|X) \\ &= 0 + E(e|X) = 0. \end{aligned}$$

- Det er nok, at $E(e|X)$ er konstant: Konstantleddet absorberer middelværdien.
- Antagelsen $E(e|X) = 0$ gælder fx, hvis e er uafhængig af $x_1, x_2, \dots, x_k$.
- Så vil **OLS-estimatoren** i en model med målefejl i den afhængige variabel stadig være **middelfret og konsistent**.

Målefejl i den afhængige variabel

Er $E(e|X) = 0$ en realistisk antagelse?

- Ofte ja.
- Men ikke altid.
- Hvis rige underrapporterer deres indkomst/formue.

Målefejl i den afhængige variabel

Hvad med variansen på OLS-estimatoren?

- Hvis u og e er ukorrelerede og homoskedastiske, får vi

$$\text{var}(u + e|X) = \sigma_u^2 + \sigma_e^2 > \sigma_u^2.$$

Dvs. større varians af fejleddet, hvis der er målefejl i den afhængige variabel.

→ Større varians på parameterestimatoren $\text{var}(\hat{\beta}_j|X)$ og mindre præcision.

Multiplikative målefejl

Nogle gange giver det mere mening at antage, at målefejlen er multiplikativ.

- Fx hvis størrelsen af målefejlene er proportional med y -variablen.
- Afhængig variabel:

$$y = y^* \cdot a, \quad a > 0$$

Logaritmen gør målefejlen additiv:

$$\begin{aligned}\log(y) &= \log(y^*) + \log(a) \\ &= \log(y^*) + e,\end{aligned}$$

hvor $e = \log(a)$.

Dvs. vi er tilbage i setuppet fra før. Men logaritmen løser kun problemet, hvis $E(\log(a)|X)$ er konstant.

Målefejl i forklarende variable

Vi betragter igen den sande model

$$y = \beta_0 + \beta_1 x^* + u,$$

hvor MLR.1-MLR.4 er opfyldt.

- x^* er ikke observeret.
- Forholdet mellem x^* og det observerede x bestemmer konsekvensen.

To tilfælde:

1. $x^* = x + e$ og $E(e|x) = 0$: Berkson-målefejl.
2. $x = x^* + e$ og $\text{cov}(e, x^*) = 0$: Klassisk målefejl.

Tilfælde 1: Berkson-målefejl

Indsæt $x^* = x + e$ i modellen:

$$\begin{aligned}y &= \beta_0 + \beta_1 x^* && + u \\&= \beta_0 + \beta_1 (x + e) && + u \\&= \beta_0 + \beta_1 x && + u + \beta_1 e.\end{aligned}$$

Hvis $E(u|x) = 0$ og $E(e|x) = 0$, er det nye fejllad middelret:

$$E(u + \beta_1 e|x) = 0.$$

Derfor er OLS middelret og konsistent. Berkson-målefejl opstår fx, når alle i en gruppe tildeles samme mål, mens deres sande værdier varierer omkring gruppemålet.

Tilfælde 2: Klassisk målefejl

Indsæt igen $x^* = x - e$ i modellen

$$y = \beta_0 + \beta_1 x + u - \beta_1 e.$$

Antag $\text{cov}(u, x^*) = \text{cov}(u, e) = \text{cov}(e, x^*) = 0$. For det nye fejllid gælder:

$$\begin{aligned}\text{cov}(u - \beta_1 e, x) &= \text{cov}(u - \beta_1 e, x^* + e) \\ &= -\beta_1 \text{var}(e) = -\beta_1 \sigma_e^2.\end{aligned}$$

Det observerede x er derfor korreleret med det nye fejllid.

Tilfælde 2: Klassisk målefejl

Den asymptotiske bias af $\hat{\beta}_1$ er nu

$$\begin{aligned} p \lim \hat{\beta}_1 - \beta_1 &= \frac{\text{cov}(u - \beta_1 e, x)}{\text{var}(x)} \\ &= -\beta_1 \frac{\sigma_e^2}{\text{var}(x^* + e)} \\ &= -\beta_1 \frac{\sigma_e^2}{\sigma_{x^*}^2 + \sigma_e^2} \end{aligned}$$

Dermed er sandsynlighedsgrænsen

$$p \lim \hat{\beta}_1 = \beta_1 \frac{\sigma_{x^*}^2}{\sigma_{x^*}^2 + \sigma_e^2}.$$

Tilfælde 2: Klassisk målefejl

Konklusion: OLS-estimatoren er inkonsistent og attenueret mod nul, da

$$0 < \frac{\sigma_{x^*}^2}{\sigma_{x^*}^2 + \sigma_e^2} < 1$$

- Hvis $\beta_1 > 0$ så er $p \lim \hat{\beta}_1 < \beta_1$
- Hvis $\beta_1 < 0$ så er $p \lim \hat{\beta}_1 > \beta_1$
- Jo større målefejlsvariansen er, jo større er den asymptotiske bias.

Dette kalder vi typisk for **attenuation bias**.

For flere forklarende variable bliver det mere kompliceret.

- Målefejl i én regressor kan generelt påvirke flere koefficienter, og retningen er ikke nødvendigvis mod nul.

Tilfælde 2: Klassisk målefejl

Quiz

Sand model

$$y = 1 + 2x^* + u$$

$$x = x^* + e$$

hvor

- $\text{cov}(e, x^*) = 0$ (klassisk målefejl)
- $x^* \sim N(2, 1)$, $u \sim N(0, 1)$, $e \sim N(0, 1)$

Estimationsmodel

$$y = \beta_0 + \beta_1 x + v$$

Hvad er sandsynlighedsgrænsen for OLS-estimatoren $\hat{\beta}_1$?

Monte Carlo Simulation

Den sande model

$$y = \beta_0 + \beta_1 x^* + u.$$


Setup og antagelser:

- Antallet af replikationer 1000
- Antallet af observationer $n = 100$
- $x = x^* + e$
- $\text{cov}(e, x^*) = 0$ (klassisk målefejl).
- Parametre: $\beta_0 = 1, \beta_1 = 2$.
- Fordelingen: $x^* \sim N(2, 1), u \sim N(0, 1), e \sim N(0, 1)$

Regressionsmodel


$$y = \beta_0 + \beta_1 x + v$$

Monte Carlo: $\text{var}(e) = 1$



$\hat{\beta}_1$ er centreret omkring $2 \cdot 1/(1 + 1) = 1$.

Monte Carlo: $\text{var}(e) = 0.5$



$\hat{\beta}_1$ er centreret omkring $2 \cdot 1/(1 + 0.5) = 4/3$.



- **Jupyter Notebook:** `11_simulation_examples.ipynb`
- **Part 1:** Målefejl i den forklarende variabel
- Eksperimenter med attenuation bias og målefejlsvarians

Dataproblemer

- **Stikprøveudvælgelse:** Hvem ender i den observerede stikprøve?
 - Manglende observationer.
 - Udvalgelse foretaget af økonometrikeren.
- **Ekstreme observationer:** Enkelte observationer kan få stor betydning for OLS.

Stikprøveudvælgelse er ikke automatisk et problem. Det afgørende er, hvordan observationerne udvælges.

Lad $s_i = 1$ betyde, at observation i indgår i stikprøven.

Eksempler

- Vi observerer kun timelønnen for personer, som arbejder.
- Kun særligt tilfredse eller utilfredse studerende besvarer en evaluering.
- Vi vælger selv kun at analysere personer med lav indkomst.

De observerede data kan godt være i.i.d. fra den *selekterede* population. Spørgsmålet er, om regressionen i denne population er den samme som i den oprindelige population.

En model for stikprøveudvælgelse

Udfaldsligningen er

$$y_i = \beta_0 + \beta_1 x_i + u_i.$$

Selektionen bestemmes af

$$s_i^* = \delta_0 + \delta_1 x_i + v_i,$$

$$s_i = 1(s_i^* > 0).$$

Vi observerer kun y_i , når $s_i = 1$.

- δ_1 bestemmer, om selektionen afhænger af x_i .
- $\rho = \text{corr}(u_i, v_i)$ bestemmer, om selektionen afhænger af uobserverede forhold, som også påvirker y_i .

Regressionen i den observerede stikprøve

Når vi kun observerer $s_i = 1$, er den betingede regressionsfunktion

$$E(y_i|x_i, s_i = 1) = \beta_0 + \beta_1 x_i + E(u_i|x_i, s_i = 1).$$

Der er tre muligheder:

- $E(u_i|x_i, s_i = 1) = 0$: Samme regression som i populationen.
- $E(u_i|x_i, s_i = 1) = c$: Konstantleddet ændres, men hældningen bevares.
- $E(u_i|x_i, s_i = 1)$ varierer med x_i : Hældningen bliver generelt biased.

Det er altså ikke manglende observationer i sig selv, men selektionsmekanismen, som er afgørende.

Hvad bestemmer selektionsbias?

Selektionsmodel	Sammenhæng	Konsekvens
$\delta_1 = 0, \rho = 0$	Tilfældig selektion	Ingen bias
$\delta_1 \neq 0, \rho = 0$	Selektion alene på x	Ingen bias
$\delta_1 = 0, \rho \neq 0$	Selektion på u , ikke på x	Konstantleddet ændres
$\delta_1 \neq 0, \rho \neq 0$	Selektion på både x og u	Hældningen ændres

Når $\rho \neq 0$, giver selektion på v_i information om u_i .

Hvis selektionsgrænsen samtidig afhænger af x_i , varierer denne information med x_i . Derfor varierer $E(u_i|x_i, s_i = 1)$ med x_i .

Udvælgelse direkte på y

Antag, at vi kun beholder observationer med $y_i < c$:

$$\begin{aligned}s_i &= 1(y_i < c) \\ &= 1(\beta_0 + \beta_1 x_i + u_i < c) \\ &= 1(u_i < c - \beta_0 - \beta_1 x_i).\end{aligned}$$

Selektionsgrænsen for u_i afhænger dermed af x_i .

$$E(u_i | x_i, s_i = 1)$$

vil derfor typisk variere med x_i , og OLS-hældningen bliver biased.

Vi simulerer fra

$$y_i = 1 + x_i + u_i,$$

$$v_i = \rho u_i + \sqrt{1 - \rho^2} e_i,$$

$$s_i = 1(\delta_1 x_i + v_i > 0),$$

hvor $x_i, u_i, e_i \sim N(0, 1)$ er indbyrdes uafhængige.

- $\rho = 0$: Selektionen indeholder ingen information om u_i .
- $\rho \neq 0$: Selektionen afhænger indirekte af u_i .
- $\delta_1 \neq 0$: Selektionsgrænsen varierer med x_i .

Hvad forudsiger teorien for $\hat{\beta}_0$ og $\hat{\beta}_1$?



Monte Carlo: Resultater

1.000 replikationer med $n = 1.000$:

Selektion	δ_1	ρ	Gns. $\hat{\beta}_0$	Gns. $\hat{\beta}_1$
Tilfældig	0	0	1.000	1.001
Kun på x	1	0	1.001	1.001
Kun på u	0	0.7	1.559	0.999
På x og u	1	0.7	1.579	0.674


- Selektion alene på x ændrer ikke regressionskoefficienterne.
- Selektion alene på u ændrer her kun konstantleddet.
- Selektion på både x og u ændrer også hældningen.

Grafisk illustration: Udvælgelse på x



Ved en korrekt lineær model ændrer udvælgelse på x ikke populationshældningen.

Grafisk illustration: Udvælgelse på y



Udvælgelse på y er implicit udvælgelse på både x og u . Derfor ændres den estimerede hældning.

Stikprøveudvælgelse: Hvad skal vi huske?

$$E(y_i|x_i, s_i = 1) = \beta_0 + \beta_1 x_i + E(u_i|x_i, s_i = 1).$$

- Selektion er uproblematisk, hvis den betingede regressionsfunktion bevares.
- En konstant ændring i $E(u_i|x_i, s_i = 1)$ ændrer kun konstantleddet.
- Hvis $E(u_i|x_i, s_i = 1)$ varierer med x_i , bliver hældningen generelt biased.

Modellen for s_i fortæller os, hvilken situation vi befinder os i.



- **Jupyter Notebook:** `11_simulation_examples.ipynb`
- **Part 2:** Eksperimenter med δ_1 og ρ
- Sammenlign tilfældig, eksogen og endogen selektion

Ekstreme observationer

Ekstreme observationer er observationer, som skiller sig ud relativt til resten af stikprøven.

Ekstreme observationer kan have stor betydning for OLS-estimerne.

- En **outlier** har et stort residual.
- En observation med **høj leverage** har ekstreme værdier af de forklarende variable.
- En **indflydelsesrig observation** ændrer estimerne mærkbart.

Hvorfor optræder der ekstreme observationer?

- Datafejl fx indtastningsfejl.
- Databehandling, fx beregning af timeløn for personer med meget få timer.
- Nogle observationer er reelt ekstreme, fx meget store virksomheder eller meget høje indkomster.

Hvad skal vi gøre med ekstreme observationer?

- Kontrollér først, om observationen skyldes en datafejl, og ret fejlen ved kilden.
- Estimer med og uden de ekstreme observationer og se hvor stor forskel det gør.
- Brug kun transformationer, fx logaritmer, når de er økonomisk og statistisk meningsfulde.
- Der findes estimatorer, som er mindre følsomme over for ekstreme observationer.

Opsummering

- En proxyvariabel kan reducere bias og i visse tilfælde genskabe middelretheden af OLS.
- Ikke-differentiel målefejl i den afhængige variabel giver typisk mindre præcise OLS-estimer.
- Klassisk målefejl i en enkelt forklarende variabel giver attenuation mod nul i simpel regression.
- Ved stikprøveudvælgelse er den centrale størrelse $E(u|X, s = 1)$.
- En konstant ændring påvirker kun konstantleddet; varierer den med X , bliver hældningerne generelt biased.