Gentagne tværsnit og paneldata

Økonometri A

Bertel Schjerning

Program

Gentagne tværsnit (W13.1)

Difference-in-Differences (W13.2)

- MLR.4 i DiD analyser
- Udvidelser af DiD setuppet

Paneldata

- First differences (W13.3-W13.5, W13.A)
- Fixed effects (W14.1)
- Random effects (W14.2)
- Andre typer panel data (W14.5)

Gentagne tværsnit

Gentagne tværsnit: datastruktur

Vi betragter nu gentagne tværsnit fra flere tidsperioder.

Eksempel ($T = 2$):

- Periode 1, $t = 1$ og en stikprøve på n_1 observationer:

$$(y_{i1}, x_{i11}, x_{i12}, x_{i13}, ..., x_{i1k}) \; i = 1, 2, 3, ..., n_1.$$

- Periode 2, $t = 2$ og en stikprøve på n_2 observationer:

$$(y_{i2}, x_{i21}, x_{i22}, x_{i23}, ..., x_{i2k}) \; i = n_1 + 1, n_1 + 2, ..., n_1 + n_2.$$

Vi følger ikke de samme individer over tid. Derfor tæller i videre fra n_1 i periode 2.

I hver periode antager vi en tilfældig stikprøve fra den relevante population.

Eksempler på gentagne tværsnit

Eksempler på gentagne tværsnit:

- **Forbrugerundersøgelsen:** Hvert år udtager DST en ny tilfældig stikprøve fra populationen (ca. 2000 husstande), som registrerer deres forbrug.
- **Hussalg:** Vi har kun huspriser på handlede huse. Kun få huse sælges flere år i træk. Vi kan se på det som en stikprøve af huspriser på handlede huse.
- **Meningsmålinger:** Firmaer som fx Gallup og Epinion spørger løbende en stikprøve om deres opbakning til politiske partier. Typisk ny stikprøve hver gang.

Generelt er det meget billigere at indsamle data som gentagne tværsnit sammenlignet med at følge folk over tid.

Pooling eller separate modeller?

Vi kan grundlæggende tilgå data på 3 måder:

- **Metode 1: Pool alle observationer.**
  - Estimer $y = X\beta + u$ med alle observationerne: $\hat{\beta}^{pool}$.
  - Modellen indeholder i alt $k + 1$ parametre.
  - Fordel: flere observationer og typisk mere præcision.
- **Metode 2: Separate estimationer**
  - Estimer $y = X\beta + u$ kun med observationer fra $t = 1$: $\hat{\beta}^1$
  - Estimer $y = X\beta + u$ kun med observationer fra $t = 2$: $\hat{\beta}^2$
  - Modellen indeholder i alt $2(k + 1)$ parametre.
  - Fordel: kan besvare nye spørgsmål (har β ændret sig over tid?)
- **Metode 3: En mellemting mellem metode 1 og 2.**
  - Pooled estimation, men lad nogle parametrene variere på tværs af tidsperioderne.
  - Antallet af parametre er s med $k + 1 < s < 2(k + 1)$.

Tidsdummier og parameterstabilitet

Vi kan teste, om parametrene ændrer sig over tid. Betragt

$$y_{it} = \beta_0 + \beta_1 x_{it1} + \beta_2 x_{it2} + u_{it} \tag{1}$$

Hvis vi estimerer denne ligning på det poolede data, antager vi at β'erne er konstante over tid.

Vi kan tillade, at parametrene ændrer sig ved at interagere variablene med dummier (som vi så i W7).

Antag at $T = 2$ og definer en dummy variabel $d2$ som

$$d2_{it} = \begin{cases} 1 \text{ hvis individ } i \text{ er obs. i periode 2} \\ 0 \text{ hvis individ } i \text{ er obs. i periode 1} \end{cases}$$

Interaktioner tillader ændrede hældninger

En tidsdummy tillader ændret konstantled:

$$y_{it} = \beta_0 + \delta_0 d2_{it} + \beta_1 x_{it1} + \beta_2 x_{it2} + u_{it}.$$

Med interaktioner kan hældningerne også ændre sig:

$$\begin{aligned} y_{it} = \beta_0 &+ \delta_0 d2_{it} \\ &+ (\beta_1 + \delta_1 d2_{it}) x_{it1} + (\beta_2 + \delta_2 d2_{it}) x_{it2} + u_{it}. \end{aligned}$$

- Periode 1: parametre $\boldsymbol{\beta}$.
- Periode 2: parametre $\boldsymbol{\beta} + \boldsymbol{\delta}$.
- Parameterstabilitet: $H_0 : \delta_0 = \delta_1 = \delta_2 = 0$.

Et (robust) F-test undersøger de fælles restriktioner.

Løn, uddannelse og køn: modellen

To uafhængige CPS-tværsnit fra 1978 og 1985: $n = 1.084$ ansatte.

$$\begin{aligned}\log(\mathit{wage}) = \beta_0 &+ \delta_0 \mathit{d85} + \beta_1 \mathit{educ} + \delta_1(\mathit{d85} \cdot \mathit{educ}) \\ &+ \beta_2 \mathit{exper} + \beta_3 \mathit{exper}^2 + \beta_4 \mathit{union} \\ &+ \beta_5 \mathit{female} + \delta_5(\mathit{d85} \cdot \mathit{female}) + u.\end{aligned}$$

- δ_1: ændringen i uddannelseskoefficienten fra 1978 til 1985.
- δ_5: ændringen i det betingede løngab mellem kvinder og mænd.

Det er ændringer i betingede sammenhænge. En kausal fortolkning kræver yderligere antagelser om uddannelse og arbejdsmarkedsvalg.

Løn, uddannelse og køn: resultater

$$\begin{aligned}\log(wage) = {} & .459 + .118\, y85 + .0747\, educ + .0185\, y85{\cdot}educ \\ & \quad (.093) \quad (.124) \qquad (.0067) \qquad (.0094) \\ & + .0296\, exper - .00040\, exper^2 + .202\, union \\ & \quad (.0036) \qquad (.00008) \qquad (.030) \\ & - .317\, female + .085\, y85{\cdot}female \\ & \quad (.037) \qquad (.051) \\ n = 1{,}084,\ & R^2 = .426,\ \bar{R}^2 = .422.\end{aligned} \qquad \textbf{[13.2]}$$

- Uddannelseskoefficient: 0,0747 i 1978 og $0{,}0747 + 0{,}0185 = 0{,}0932$ i 1985. Stigning ca. 1,85 procentpoint; $t \approx 1{,}97$, på grænsen ved 5%.
- Kønskoefficient: $-0{,}317$ i 1978 og $-0{,}317 + 0{,}085 = -0{,}232$ i 1985. Det negative log-løngab bliver mindre; ændringen er ikke signifikant ved 5%.

Koefficienter til log(*wage*) fortolkes her med den sædvanlige procentapproksimation.

Difference-in-Differences

Difference-in-Differences (DiD)

Gentagne tværsnit gør det muligt at lave såkaldte **Difference-in-Differences (DiD)** analyser.

- En af de mest brugte estimationsmetoder i Økonomi.
- Særligt brugbar til analyser af "politikindgreb" / naturlige eksperimenter.

I sin rene form kræver en DiD analyse to ting af data:

- Data for to grupper, hvoraf den ene er påvirket af et politikindgreb (treatment gruppen) og en gruppe, som ikke er påvirket (control gruppen).
- Data for de to grupper både før og efter politikindgrebet.

Ved at have data for før indgrebet kan vi kontrollere for forskelle mellem grupperne, som ikke skyldes indgrebet.

Huspriser: placeringen er ikke tilfældig

Hypotese: Beslutningen om et forbrændingsanlæg sænker lokale huspriser.

$$rprice_i = \beta_0 + \beta_1 near_i + u_i. \tag{2}$$

rprice er real huspris; $near = 1$ for huse tæt på det kommende anlæg.

- Anlæg placeres ofte i områder med billig jord, industri og lavere boligefterspørgsel.
- Hvis disse forhold ikke observeres, er $E(u \mid near = 1) < E(u \mid near = 0)$.
- OLS blander da anlæggets effekt med eksisterende områdeforskelle og får negativ bias.

Vi har brug for en model for, hvordan priserne ville have udviklet sig uden beslutningen.

Huspriser efter beslutningen: 1981

Hussalg i området omkring Boston i 1978 og 1981. Beslutningen om anlægget ligger mellem de to tværsnit; anlægget blev først opført i 1985.

$$\widehat{rprice} = 101{,}3 - 30{,}7 \cdot near.$$

Priser i tusinde 1978-dollars.

- Huse langt fra anlægget koster i gennemsnit 101.300 dollars.
- Huse tæt på koster i gennemsnit 30.700 dollars mindre.
- Forskellen kan skyldes både beslutningen og forskelle, der allerede fandtes før beslutningen.

Huspriser før beslutningen: 1978

Samme regression på 1978-data:

$$\widehat{rprice} = 82{,}5 - 18{,}8 \cdot near.$$

Allerede før beslutningen kostede huse tæt på det kommende anlæg mindre.

- Antag, at prisforskellen uden beslutningen ville have været konstant over tid.
- Så kan vi trække forskellen før beslutningen fra forskellen efter:

$$\hat{\delta}_1 = -30{,}7 - (-18{,}8) = -11{,}9.$$

Beslutningen er forbundet med et relativt prisfald på ca. 11.900 1978-dollars.

DiD: ændringen i prisforskellen

	Tæt på	Langt fra	Forskel
1978	63,7	82,5	−18,8
1981	70,6	101,3	−30,7
Ændring	6,9	18,8	−11,9

Gennemsnitlige huspriser i tusinde 1978-dollars.

$$\hat{\delta}_1 = (70{,}6 - 63{,}7) - (101{,}3 - 82{,}5) = -11{,}9.$$

- Priserne tæt på anlægget stiger faktisk.
- Under parallelle trends ville de være steget 11,9 mere uden beslutningen.

DiD som en regression

$$rprice_{it} = \beta_0 + \delta_0 d81_{it} + \beta_1 near_{it} + \delta_1 (d81_{it} \cdot near_{it}) + u_{it}. \tag{3}$$

- $d81$: efter-dummy. $near$: gruppe-dummy. $d81 \cdot near$: interaktion.
- δ_0: ændringen i kontrolområdet. β_1: prisforskellen i 1978.
- δ_1: ændringen i prisforskellen, dvs. DiD-estimatet.

	Tæt på	Langt fra	Forskel
1978	$\beta_0 + \beta_1$	β_0	β_1
1981	$\beta_0 + \delta_0 + \beta_1 + \delta_1$	$\beta_0 + \delta_0$	$\beta_1 + \delta_1$
Ændring	$\delta_0 + \delta_1$	δ_0	δ_1

Huspriser: DiD med kontrolvariable

$$rprice = \beta_0 + \delta_0 y81 + \beta_1 nearinc + \delta_1 (y81 \cdot nearinc) + \mathbf{X}\boldsymbol{\theta} + u.$$

TABLE 13.2 Effects of Incinerator Location on Housing Prices

Dependent Variable: *rprice*			
Independent Variable	**(1)**	**(2)**	**(3)**
constant	82,517.23 (2,726.91)	89,116.54 (2,406.05)	13,807.67 (11,166.59)
y81	18,790.29 (4,050.07)	21,321.04 (3,443.63)	13,928.48 (2,798.75)
nearinc	−18,824.37 (4,875.32)	9,397.94 (4,812.22)	3,780.34 (4,453.42)
y81·nearinc	−11,863.90 (7,456.65)	−21,920.27 (6,359.75)	−14,177.93 (4,987.27)
Other controls	No	*age*, age^2	Full Set
Observations	321	321	321
R-squared	.174	.414	.660

Tabellen bruger dollars. De tidligere gennemsnit var i tusinde dollars.

Huspriser: sådan læses resultaterne

- $y81$: ændringen for kontrolområdet. *nearinc*: niveauforskellen før beslutningen.
- $y81 \cdot$ *nearinc* er DiD-leddet.
- Uden ekstra kontroller: $\hat{\delta}_1 = -11.864$ dollars, SE 7.457. Punktestimatet er negativt, men ikke signifikant ved 5%.
- Med fuldt sæt kontroller: $\hat{\delta}_1 = -14.178$ dollars, SE 4.987.

Tabellens SE er konventionelle. Kontroller justerer for forskelle i de handlede huses karakteristika. En kausal fortolkning kræver fortsat en troværdig antagelse om udviklingen uden beslutningen.

DiD: gennemsnit og regression

Uden ekstra kontroller er regressionsestimatet:

$$\begin{aligned}\hat{\delta}_1 &= (\bar{y}_{\text{efter, beh.}} - \bar{y}_{\text{efter, kontrol}}) - (\bar{y}_{\text{før, beh.}} - \bar{y}_{\text{før, kontrol}}) \\ &= (\bar{y}_{\text{efter, beh.}} - \bar{y}_{\text{før, beh.}}) - (\bar{y}_{\text{efter, kontrol}} - \bar{y}_{\text{før, kontrol}}).\end{aligned}$$

Gruppeforskelle eller tidsforskelle først giver samme resultat, når fortegnene bevares.

$$y = \beta_0 + \delta_0 \mathit{post} + \beta_1 \mathit{treat} + \delta_1 (\mathit{post} \cdot \mathit{treat}) + \mathbf{X}\boldsymbol{\theta} + u.$$

- Med $\mathbf{X}$ er estimatet justeret og generelt forskelligt fra de fire rå gennemsnit.
- Kontroller påvirket af indgrebet kan ændre, hvilken effekt vi estimerer.

MLR.4 i DiD analyser

Grundlæggende adskiller DiD-analyser sig ikke fra andre regressionsanalyser.

Men vi er ikke interesseret i alle parameterestimaterne. For et konsistent estimat af "behandlingseffekten" (δ_1) kræver vi kun:

$$\underbrace{E(u|post = 1, treatment = 1) - E(u|post = 1, treatment = 0)}_{\text{Bias efter indgreb}} =$$

$$\underbrace{E(u|post = 0, treatment = 1) - E(u|post = 0, treatment = 0)}_{\text{Bias før indgreb}}$$

Dette er en svagere antagelse end $E(u|post, treatment) = 0$. Vi kræver ikke at bias er 0 generelt. Blot at den er konstant over tid.

Parallelle trends er en kontrafaktisk antagelse

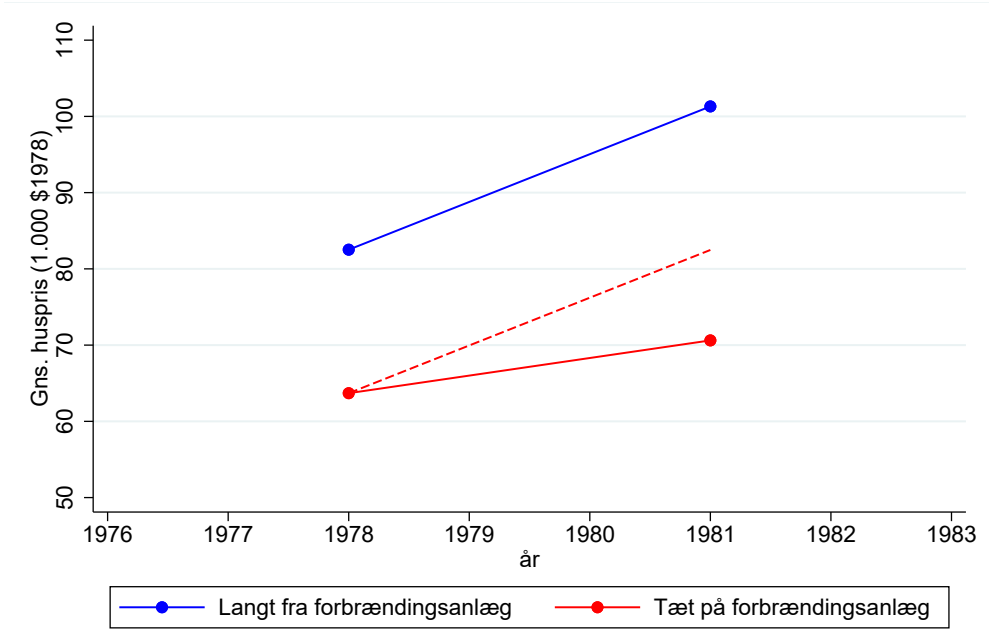
Uden beslutningen om anlægget antager vi samme prisudvikling for huse tæt på og langt fra:

$$\Delta\text{pris uden indgreb, behandlet} = \Delta\text{pris, kontrol.}$$

- Grupperne må gerne have forskellige prisniveauer før indgrebet.
- Vi observerer ikke behandlingsområdets udvikling efter T uden indgrebet.
- Ens udvikling før T kan understøtte antagelsen, men beviser den ikke.

Økonomisk argumentation er nødvendig: Hvorfor skulle fx lokal boligefterspørgsel have udviklet sig ens uden beslutningen?

Parallelle trends: den kontrafaktiske huspris



- Blå: kontrolområdet. Rød: området tæt på anlægget.
- Rød stiplet: kontrafaktisk udvikling ved samme stigning som i kontrolområdet. DiD er observeret minus kontrafaktisk pris i 1981.

Flere perioder: hvad kan vi undersøge?

- Flere perioder før indgrebet giver mulighed for at undersøge, om gruppernes udvikling tidligere var parallel.
- Flere perioder efter indgrebet viser, om effekten opstår straks, vokser eller aftager.
- Et fælles test af koefficienterne før indgrebet kan afsløre forskelle i præ-trends.

Et ikke-forkastet test beviser ikke identifikationsantagelsen. Testet kan have lav styrke, og nye gruppespecifikke chok kan opstå efter indgrebet.

Flere perioder før indgrebet

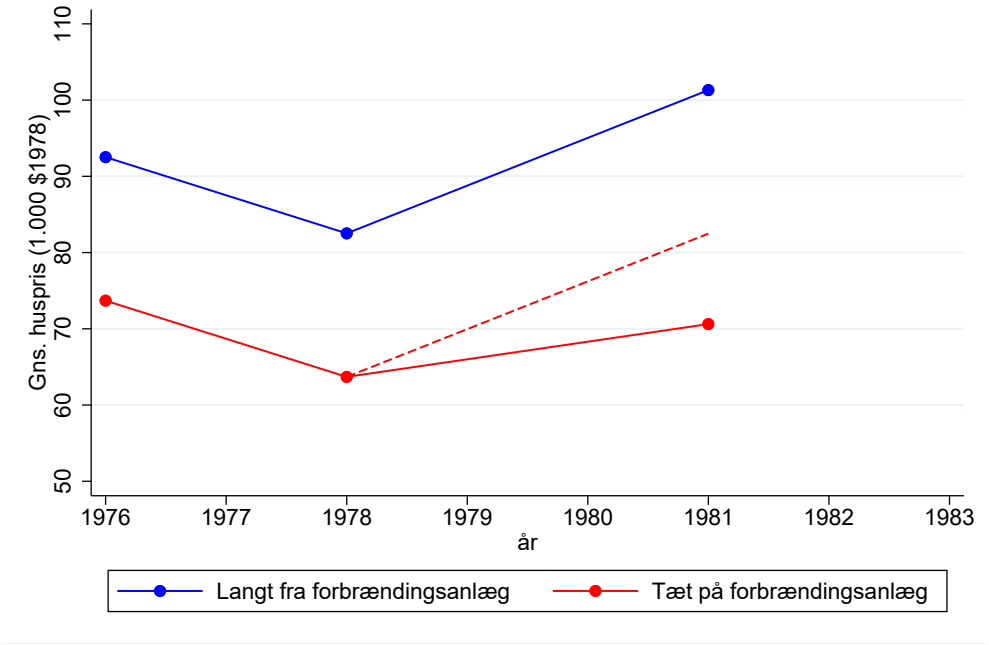


Illustration: ekstra før- og efterperioder er hypotetiske, ikke yderligere Kielmc-observationer.

- Førperioderne viser her samme ændring i de to grupper. Det understøtter, men beviser ikke, den kontrafaktiske antagelse.

Flere perioder efter indgrebet

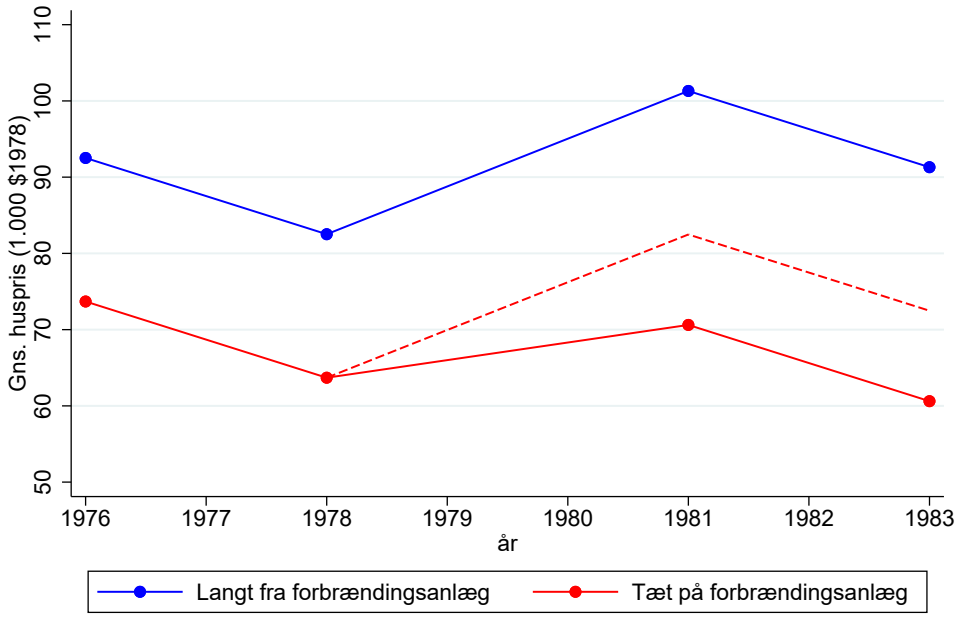


Illustration: ekstra før- og efterperioder er hypotetiske, ikke yderligere Kielmc-observationer.

- Den stiplede linje viderefører behandlingsområdets niveau med kontrolområdets udvikling. Afstanden til den observerede pris kan ændre sig over tid.

Et event study viser effekter over tid

- Vi estimerer en særskilt forskel mellem grupperne for hver periode, relativt til en fælles referenceperiode.
- Før indgrebet undersøger vi, om forskellen mellem grupperne allerede var ved at ændre sig.
- Efter indgrebet beskriver koefficienterne forløbet relativt til udviklingen i kontrolgruppen.

Fortolkningen kræver bl.a. parallelle kontrafaktiske trends og ingen effekt før det angivne behandlingstidspunkt.

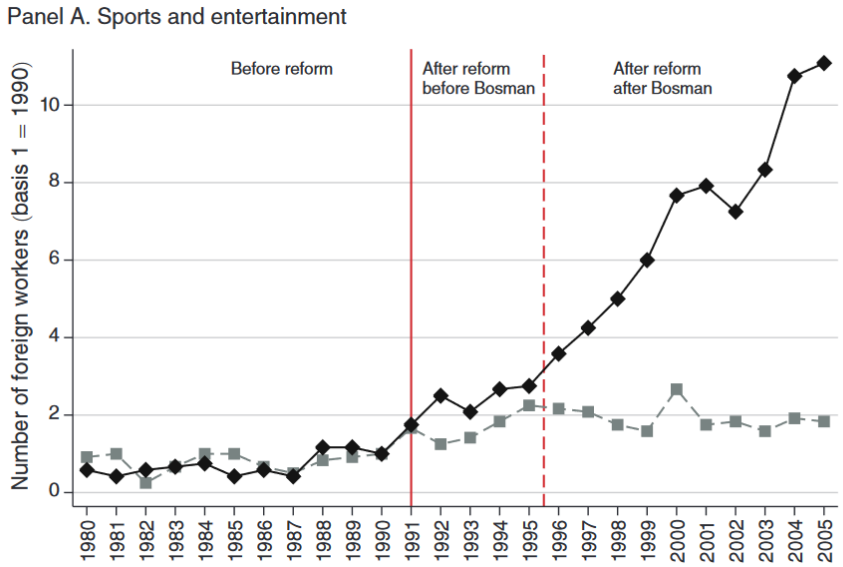
Event-study-regression med fælles behandlingstidspunkt

Lad $D_{kt} = 1$, hvis observationen er k perioder fra indgrebet. Året før, $k = -1$, er referenceperiode.

$$y_{it} = \beta_0 + \beta_1 treat_i + \sum_{k \neq -1} \delta_k D_{kt} + \sum_{k \neq -1} \gamma_k (D_{kt} \cdot treat_i) + \mathbf{X}_{it}\boldsymbol{\theta} + u_{it}.$$

- Både tidsdummyen og interaktionen for $k = -1$ udelades.
- γ_k: forskellen mellem grupperne i periode k, minus forskellen i referenceåret.
- Præ-trend-test: $H_0 : \gamma_k = 0$ for alle estimerede $k < -1$.
- For $k \geq 0$ beskriver γ_k de dynamiske effekter under identifikationsantagelserne.

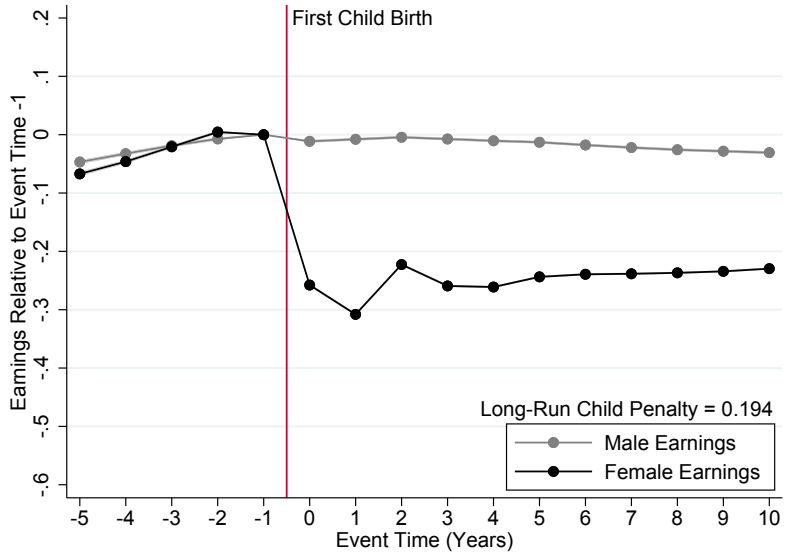
Skat og tilflytning af udenlandske ansatte



- Sort: udenlandske ansatte over indkomstgrænsen for forskerskatteordningen. Grå: ansatte lige under grænsen.
- Ordningen gjaldt fra 1991. Bosman-dommen i 1995 ændrede også fodboldspillernes mobilitet.

Kleven, Landais & Saez (2013), AER, figur 4. Serierne viser antal udenlandske ansatte inden for sport og underholdning, indekseret til 1 i 1990.

Første barn og forældrenes arbejdsindkomst



- Arbejdsindkomst omfatter beskæftigelse, arbejdstid og lønsats. Forløbene er normaliseret relativt til året før første fødsel.
- Begge grupper får børn. Figuren viser kvinders indkomstudvikling relativt til mænds, under analysens antagelser.

Kleven, Landais & Søgaard (2019), AEJ: Applied Economics. Et forløb omkring fødslen er ikke alene dokumentation for en kausal effekt.

En ekstra forskel: DiDiD

Vi kan gentage DiD-sammenligningen i et ekstra område, som ikke rammes af indgrebet:

$$\widehat{\text{DiDiD}} = \widehat{\text{DiD}}_{\text{område A}} - \widehat{\text{DiD}}_{\text{område B}}.$$

- I begge områder opdeler vi populationen i sammenlignelige grupper og perioder.
- Område B skal opfange den forskel i udvikling mellem grupperne, som også ville have været der i A uden indgrebet.
- Vi kræver derfor samme kontrafaktiske forskel i trends på tværs af områderne.

Et insignifikant placebo-DiD er ikke i sig selv bevis for antagelsen.

Et generelt DiD-setup

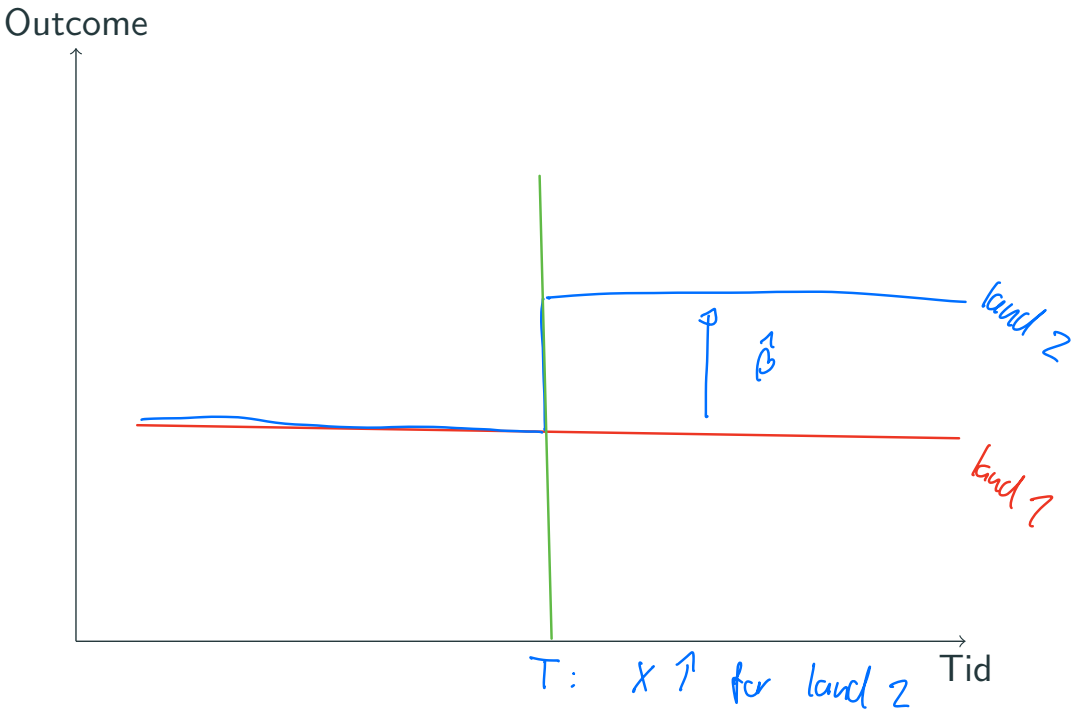
$$y_{igt} = \lambda_t + \alpha_g + \beta x_{igt} + \mathbf{Z}_{igt}\gamma + u_{igt}.$$

- λ_t: fælles tidseffekter. α_g: permanente gruppeforskelle.
- x_{igt}: fx en skattesats, mindsteløn eller indikator for et indgreb.
- β: effekten af én enheds ændring i x, antaget fælles på tværs af grupper og tid.
- I huspriseksemplet er $x_{igt} = d81_{it} \cdot near_{it}$.

Modellen udnytter politikændringer relativt til gruppe- og tidseffekterne. Identifikation kræver, at den resterende variation i x er eksogen i forhold til u.

DiD: Et niveauskift ved indgrebet

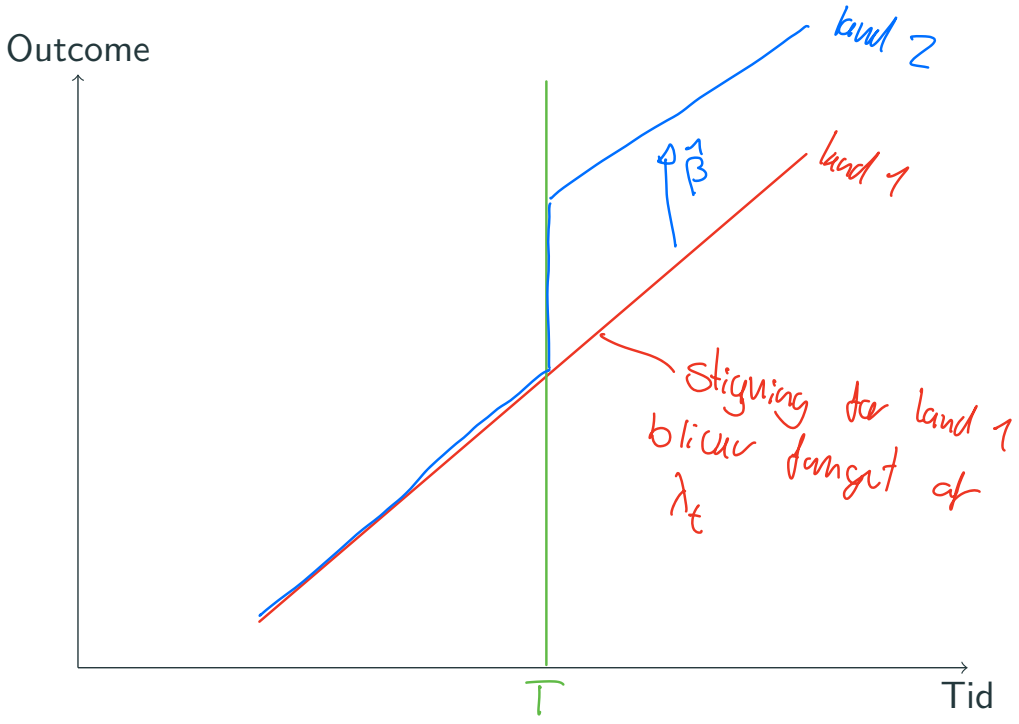
$$y_{igt} = \lambda_t + \alpha_g + \beta x_{igt} + \mathbf{Z}_{igt}\gamma + u_{igt}$$



- Når x stiger med én enhed i land 2 ved T, måler β niveauskiftet relativt til land 1.

DiD: En fælles trend fjernes

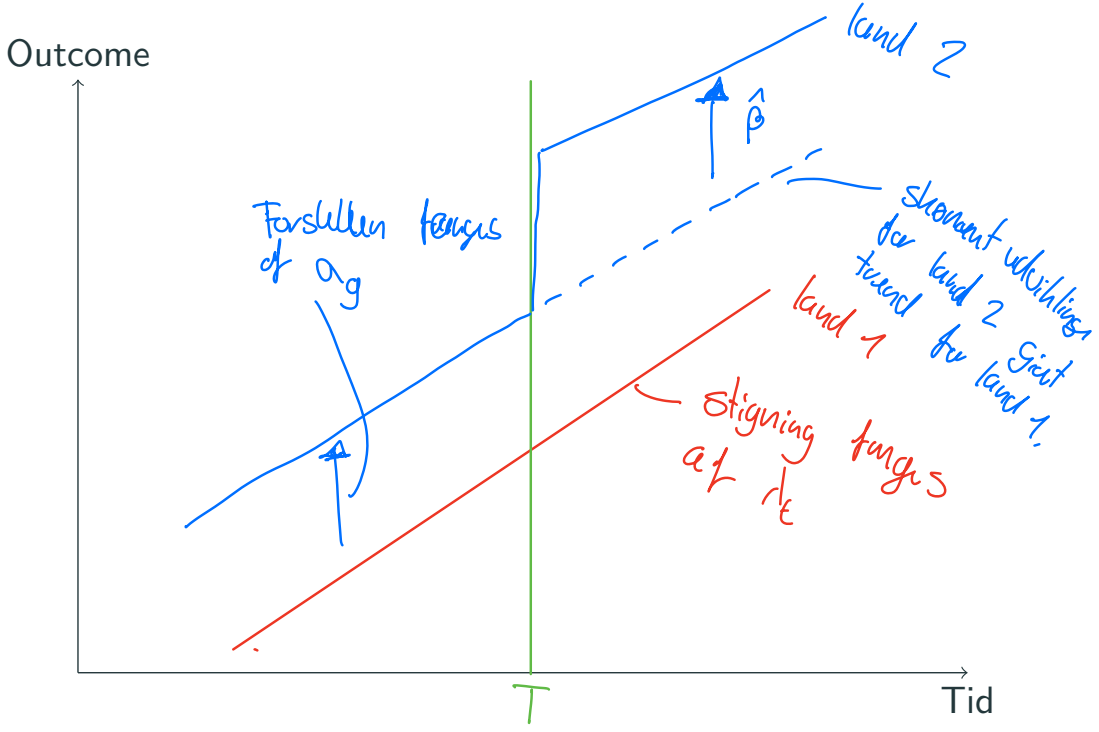
$$y_{igt} = \lambda_t + \alpha_g + \beta x_{igt} + \mathbf{Z}_{igt}\gamma + u_{igt}$$



- λ_t fanger den fælles udvikling. β måler land 2's ekstra ændring ved T, ud over denne udvikling.

DiD: Permanente niveauforskelle fjernes

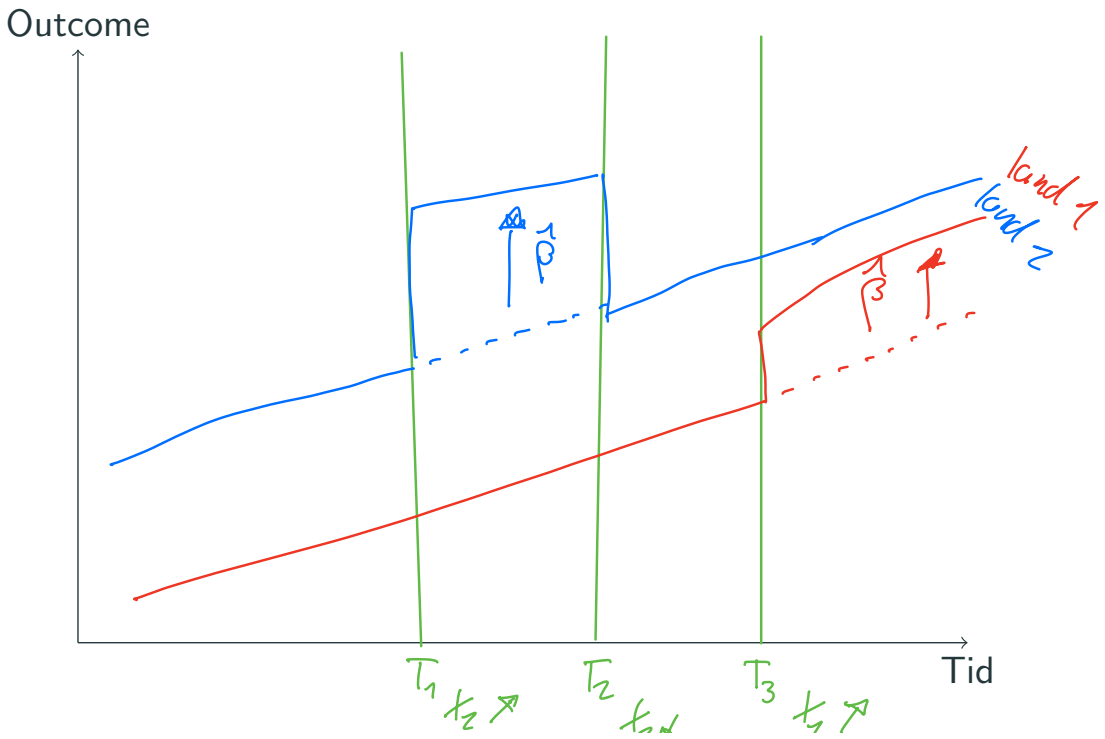
$$y_{igt} = \lambda_t + \alpha_g + \beta x_{igt} + \mathbf{Z}_{igt}\gamma + u_{igt}$$



- α_g fanger den permanente niveauforskel. Den stiplede linje er land 2's kontrafaktiske udvikling uden indgrebet.

DiD: Flere indgreb og ændret politik

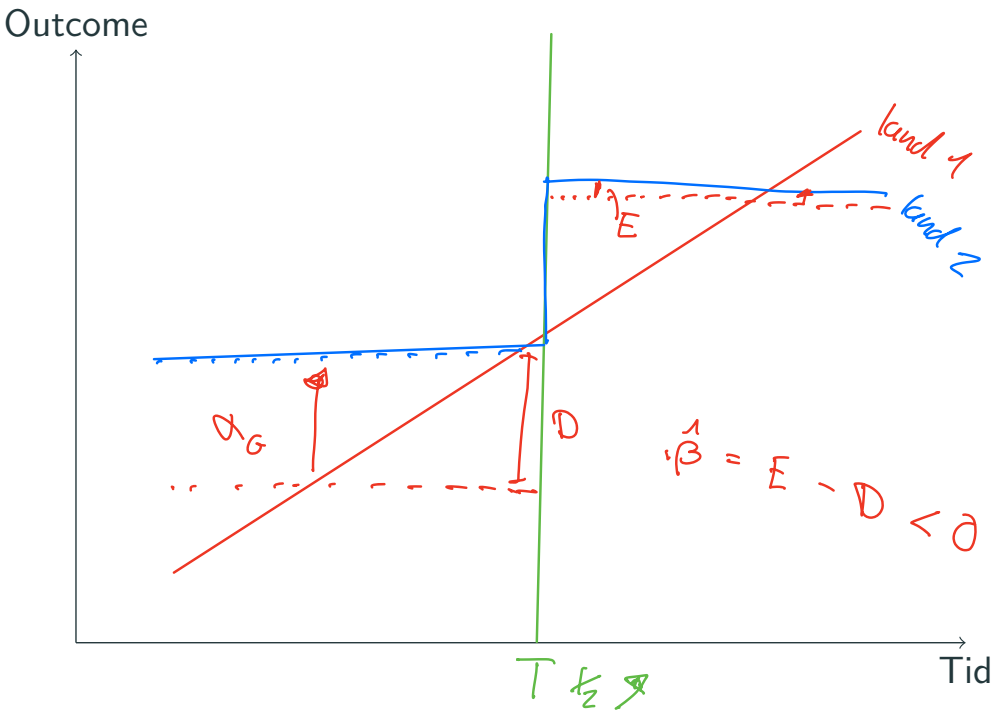
$$y_{igt} = \lambda_t + \alpha_g + \beta x_{igt} + \mathbf{Z}_{igt}\boldsymbol{\gamma} + u_{igt}$$



- Stigninger og fald i x på forskellige tidspunkter bidrager til at identificere β; modellen antager samme effekt pr. enhed x.

DiD: Forskellige trends giver bias

$$y_{igt} = \lambda_t + \alpha_g + \beta x_{igt} + \mathbf{Z}_{igt}\gamma + u_{igt}$$



- α_g og λ_t fjerner ikke forskellige trends. Her bliver $\hat{\beta} = E - D < 0$, selv om land 2 får et positivt niveauskift ved T.

Generelt DiD: antagelser og dynamik

$$y_{igt} = \lambda_t + \alpha_g + \beta x_{igt} + \mathbf{Z}_{igt}\gamma + u_{igt}.$$

- Gruppeforskellene α_g er permanente, og tidseffekterne λ_t er fælles.
- β antages ens på tværs af grupper og tid; resterende politikvariation skal være eksogen.
- Lags af x kan beskrive forsinkede effekter af politikændringer.
- Leads af x kan afsløre forudgående forskelle eller forventningseffekter.

Leads og lags garanterer ikke identifikation. Forskellige effekter ved forskudt behandling kræver særlig omtanke med tovejs-FE.

Quiz: hvilken variation identificerer politikvirkningen?

$$y_{igt} = \lambda_t + \alpha_g + \beta x_{igt} + \mathbf{Z}_{igt}\gamma + u_{igt}.$$

Er der variation tilbage i x, efter gruppe- og tidsdummierne er fjernet?

1. x varierer mellem grupper, men er konstant over tid inden for hver gruppe.
2. x varierer over tid, men er ens i alle grupper i hver periode.
3. x varierer mellem grupper og over tid. Er dette alene tilstrækkeligt? Overvej $x_{gt} = c_g + d_t$.

Vi skal også tage højde for eventuel kollinearitet med $\mathbf{Z}$.

Hjemmebesøg og senere helbred

Universal Investment in Infants and Long-Run Health: Evidence from Denmark's 1937 Home Visiting Program†

By Jonas Hjort, Mikkel Sølvsten, and Miriam Wüst*

This paper examines the long-run health effects of a universal infant health intervention, the 1937 Danish home visiting program, which targeted all infants. Using administrative population data and exploiting variation in the timing of implementation across municipalities, we find that treated individuals enjoy higher age-specific survival rates during middle age (45–64), experience fewer hospital nights, and are less likely to be diagnosed with cardiovascular disease. These results suggest that an improved nutrition and disease environment in infancy "programmed" individuals for lower predisposition to serious adult diseases. (*JEL* H51, I12, I18, J13, N34)

Hjort, Sølvsten, & Wüst. (2017). American Economic Journal: Applied Economics, 9(4)

Hjemmebesøg: kommunernes indførelsestidspunkt

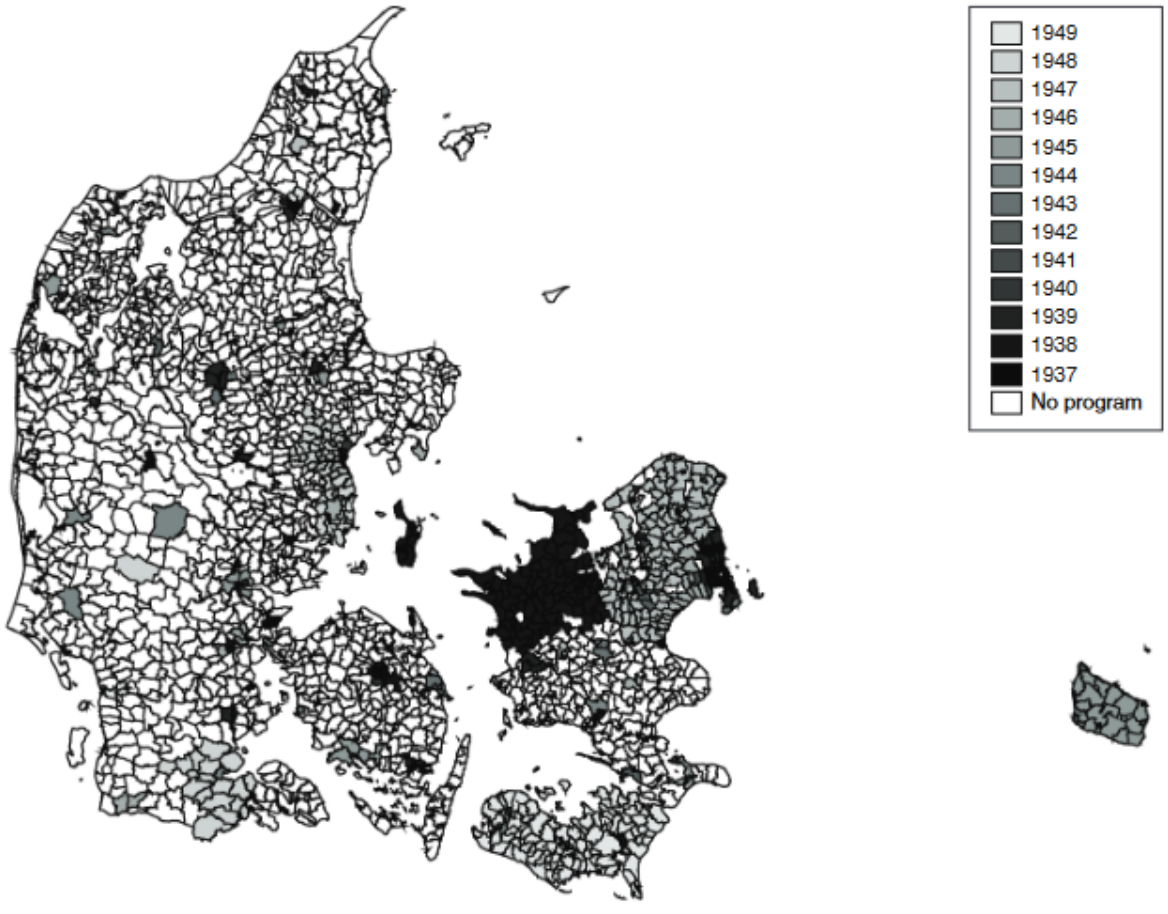


FIGURE 1. MUNICIPALITIES AND THEIR DATE OF ENTRY INTO TREATMENT, 1937–1949

Hjort, Sølvsten, & Wüst. (2017). American Economic Journal: Applied Economics, 9(4)

Hjemmebesøg: model og identifikation

$$y_{ijt} = \alpha + \beta\, homevisit_{jt} + \gamma_j + \delta_t + \varepsilon_{ijt}.$$

- y_{ijt}: helbredsudfald for person i, født i kommune j i kohorte t.
- $homevisit_{jt}$: kommunen havde programmet, da kohorten blev født.
- γ_j: permanente kommuneforskelle. δ_t: fælles kohorteforskelle.
- β udnytter, at kommunerne indfører programmet på forskellige tidspunkter.

Antagelsen er, at indførelsen ikke falder sammen med andre kommunespecifikke ændringer, som påvirker disse kohorters senere helbred.

Hjemmebesøg: overlevelse til forskellige aldre

TABLE 2—EFFECT OF THE HOME VISITING PROGRAM ON SURVIVAL BEYOND VARIOUS AGES, COHORTS 1935–1949

Outcome	All (1)	All (2)	All (3)	Matched (4)	Ever impl. (5)
Survival until age 50	0.064	0.087	0.165	0.063	0.198
	(0.063)	(0.078)	(0.081)	(0.171)	(0.096)
Mean of dependent variable × 100	98.342	98.342	98.342	98.377	98.218
Observations	20,078	20,078	20,078	6,204	5,769
Survival until age 55	0.228	0.264	0.312	0.317	0.335
	(0.091)	(0.119)	(0.120)	(0.273)	(0.151)
Mean of dependent variable × 100	95.880	95.880	95.880	95.925	95.610
Observations	20,078	20,078	20,078	6,204	5,769
Survival until age 60	0.337	0.260	0.469	0.587	0.469
	(0.123)	(0.140)	(0.167)	(0.372)	(0.207)
Mean of dependent variable × 100	92.432	92.432	92.432	92.535	91.967
Observations	20,078	20,078	20,078	6,204	5,769
Survival until age 64	0.382	0.257	0.454	0.592	0.387
	(0.155)	(0.178)	(0.195)	(0.435)	(0.235)
Mean of dependent variable × 100	88.756	88.756	88.756	88.791	88.121
Observations	20,078	20,078	20,078	6,204	5,769
Cohort fixed effects	Yes	Yes	Yes	Yes	Yes
Municipal					
Fixed effects	Yes	Yes	Yes	Yes	Yes
X (level) × year interactions	No	No	Yes	No	Yes
X (trend) × year interactions	No	No	Yes	No	Yes
Linear time trends	No	Yes	No	No	No

Hjort, Sølvsten, & Wüst. (2017). American Economic Journal: Applied Economics, 9(4)

Hjemmebesøg: størrelsen og usikkerheden

Tabellen angiver både koefficienter og standardfejl ganget med 100, dvs. i procentpoint.

- Overlevelse til 50 år, kolonne (1): 0,064 procentpoint med SE 0,063. Ikke signifikant ved 5%.
- Overlevelse til 60 år, kolonne (1): 0,337 procentpoint med SE 0,123.
- Den anden effekt svarer til ca. 3,37 ekstra overlevende pr. 1.000 børn, under identifikationsantagelserne.

Kolonnerne undersøger følsomheden over for bl.a. kommunetrends og kontrolvariable. Positive punktestimater er ikke det samme som præcise eller sikkert kausale effekter.

Kilde: Hjort, Sølvsten & Wüst (2017), tabel 2 og tabelnote.

Paneldata

Paneldata: de samme enheder over tid

Med **paneldata** observerer vi de samme enheder flere gange.

- **Balanceret panel (balanced panel):** Alle n enheder observeres i de samme T perioder. I alt nT observationer.
- **Ubalanceret panel (unbalanced panel):** Nogle enheder mangler i én eller flere perioder.
- Fx individer, virksomheder, kommuner eller lande.

Ved $T = 2$ observerer vi

$$(y_{i1}, \mathbf{x}_{i1}), \quad (y_{i2}, \mathbf{x}_{i2}), \qquad i = 1, \ldots, n.$$

Sample attrition (frafald): Hvis enheder forlader panelet, skal vi overveje, om frafaldet er systematisk. Vi tager i det følgende udgangspunkt i et balanceret panel.

Panelmodellen: permanent og tidsvarierende heterogenitet

$$y_{it} = \beta_0 + \beta_1 x_{it} + \delta_0 d2_t + a_i + u_{it}.$$

- a_i: **uobserveret heterogenitet / individuel effekt**. Permanent, fx evner eller vedvarende produktivitet.
- u_{it}: **idiosynkratisk fejlled**. Tidsvarierende, fx et sygdoms- eller produktivitetschok.
- $d2_t$: fælles ændring fra periode 1 til periode 2.

Vi tillader, at a_i er korreleret med x_{it}. Vi skal stadig begrunde, hvorfor x er eksogent i forhold til de tidsvarierende chok.

Hvornår kan vi bruge pooled OLS?

$$y_{it} = \beta_0 + \beta_1 x_{it} + \delta_0 d2_t + a_i + u_{it}. \tag{4}$$

Den sammensatte fejl er $v_{it} = a_i + u_{it}$.

$$E(v_{it} \mid x_{i1}, \ldots, x_{iT}) = 0$$

er en tilstrækkelig eksogenitetsantagelse for pooled OLS under de sædvanlige stikprøve- og rangbetingelser.

- Hvis a_i påvirker både x og y, vil den typisk være korreleret med x.
- Så er det ikke tilstrækkeligt, at u_{it} er eksogent.
- Selv ved eksogenitet skal standardfejl tage højde for afhængighed inden for enhed.

Hvad fjerner FE og FD?

$$y_{it} = \beta_0 + \beta_1 x_{it} + \delta_0 d2_t + a_i + u_{it}.$$

- Vi bruger ændringer inden for individet til at fjerne a_i.
- Evner, der er konstante over tid, kan dermed være korreleret med uddannelse eller andre valg.
- Tidsvarierende uobserverede forhold u_{it} bliver tilbage.

Eksempel: En virksomhed øger investeringerne efter et positivt produktivitetschok. Virksomheds-FE fjerner permanent produktivitet, men ikke denne reaktion på et nyt chok.

Individ-dummier og within-transformation

Vi kan estimere en lineær panelmodel med en dummy for hvert individ:

- Med konstantled bruges $n - 1$ individ-dummier.
- Dummierne tillader et særskilt niveau for hver enhed.
- FE-estimatoren kan beregnes ved at fjerne individgennemsnit i stedet. FWL giver samme hældninger som dummy-regressionen.

FD fjerner også a_i, men er kun identisk med FE, når $T = 2$.

Dummier eller transformation er et beregningsvalg. Identifikation kræver stadig brugbar variation og eksogene tidsvarierende fejlled.

Streng eksogenitet og økonomisk feedback

En tilstrækkelig antagelse for FE og FD er

$$E(u_{it} \mid x_{i1}, \ldots, x_{iT}, a_i) = 0, \qquad t = 1, \ldots, T.$$

- Dagens fejlled må ikke være systematisk relateret til fortidens, dagens eller fremtidens x.
- Et negativt lønchok kan få personen til at tage mere uddannelse næste år. Så er fremtidig uddannelse relateret til dagens fejlled.
- Det kan bryde streng eksogenitet, selv hvis dagens x er ukorreleret med dagens u.

Streng eksogenitet er tilstrækkelig; for FD kan den svagere betingelse $E(\Delta u_i \mid \Delta x_i) = 0$ være nok.

Første differenser (FD)

Vi kan omskrive ligning (4):

- Periode 1:

$$y_{i1} = \beta_0 + \beta_1 x_{i1} + a_i + u_{i1}$$

- Periode 2:

$$y_{i2} = \beta_0 + \delta_0 + \beta_1 x_{i2} + a_i + u_{i2}$$

- Første-differenser:

$$y_{i2} - y_{i1} = \delta_0 + \beta_1 (x_{i2} - x_{i1}) + a_i - a_i + u_{i2} - u_{i1}$$
$$\Delta y_i = \delta_0 + \beta_1 \Delta x_i + \Delta u_i.$$

- Den uobserverede heterogenitet a_i forsvinder.

Vi har nu et tværsnitsdatasæt med første-differenser.

FD-estimatoren

"Standard" OLS estimation af

$$\Delta y_i = \delta_0 + \beta_1 \Delta x_i + \Delta u_i.$$

Giver FD-estimatoren:

$$\hat{\beta}_1^{FD} = \frac{cov(\Delta x_i, \Delta y_i)}{var(\Delta x_i)} = \frac{\sum_{i=1}^{n} (\Delta x_i - \overline{\Delta x}) \Delta y_i}{\sum_{i=1}^{n} (\Delta x_i - \overline{\Delta x}) \Delta x_i}$$

FD: antagelser for konsistens

- **FD.1: Lineær model**

$$y_{it} = \beta_0 + \beta_1 x_{it} + \delta_0 d2_t + a_i + u_{it}.$$

- **FD.2: Tilfældig stikprøve af individer.** Observationer inden for samme individ må være afhængige.
- **FD.3: Ingen perfekt multikollinearitet.** Her kræves $\text{var}(\Delta x_i) > 0$; med flere regressorer må differenserne ikke være perfekt kollineære.
- **FD.4: Streng eksogenitet**

$$E(u_{it} \mid x_{i1}, x_{i2}, a_i) = 0, \qquad t = 1, 2.$$

FD.1–FD.4 giver middelrethed og konsistens. Vi tillader $\text{cov}(a_i, x_{it}) \neq 0$.

FD er konsistent: samme plim-trick som ved IV

$$\hat{\beta}_1^{FD} = \frac{\frac{1}{n}\sum_i (\Delta x_i - \overline{\Delta x})\Delta y_i}{\frac{1}{n}\sum_i (\Delta x_i - \overline{\Delta x})^2}.$$

Tag plim og brug FD.2–FD.3:

$$\text{plim}\, \hat{\beta}_1^{FD} = \frac{\text{cov}(\Delta x_i, \Delta y_i)}{\text{var}(\Delta x_i)}.$$

Indsæt modellen $\Delta y_i = \delta_0 + \beta_1 \Delta x_i + \Delta u_i$:

$$\begin{aligned} \text{plim}\, \hat{\beta}_1^{FD} &= \frac{\text{cov}(\Delta x_i, \delta_0 + \beta_1 \Delta x_i + \Delta u_i)}{\text{var}(\Delta x_i)} \\ &= \beta_1 + \frac{\text{cov}(\Delta x_i, \Delta u_i)}{\text{var}(\Delta x_i)}. \end{aligned}$$

Næste trin: Brug FD.4 til at vise $\text{cov}(\Delta x_i, \Delta u_i) = 0$.

FD.4: hvorfor er differenserne eksogene?

Streng eksogenitet giver $\text{cov}(x_{is}, u_{it}) = 0$ for alle s, t.

$$\begin{aligned}
\text{cov}(\Delta x_i, \Delta u_i) &= \text{cov}(x_{i2} - x_{i1}, u_{i2} - u_{i1}) \\
&= \text{cov}(x_{i2}, u_{i2}) - \text{cov}(x_{i2}, u_{i1}) \\
&\quad - \text{cov}(x_{i1}, u_{i2}) + \text{cov}(x_{i1}, u_{i1}) \\
&= 0.
\end{aligned}$$

Dermed er plim $\hat{\beta}_1^{FD} = \beta_1$.

- Det er ikke nok kun at have $\text{cov}(x_{it}, u_{it}) = 0$.
- Husk OLS-tricket for middelrethed: Beting på alle Δx_i. Så er nævneren fast, og den betingede forventning af tælleren er nul.

FD.5–FD.6: varians og seriekorrelation

Lad $\mathbf{X}_i$ indeholde alle individets regressorer i alle perioder.

- **FD.5: Homoskedasticitet i differenserne**

$$\text{var}(\Delta u_{it} \mid \mathbf{X}_i) = \sigma^2_{\Delta u}, \qquad t = 2, \ldots, T.$$

- **FD.6: Ingen seriekorrelation i differenserne**

$$\text{cov}(\Delta u_{it}, \Delta u_{is} \mid \mathbf{X}_i) = 0, \qquad t \neq s.$$

FD.1–FD.4 sikrer konsistens. FD.5–FD.6 er yderligere antagelser for de sædvanlige OLS-standardfejl og FD's efficiens.

Ved $T = 2$ har vi kun én differens pr. individ, så FD.6 tilføjer ingen restriktion.

FD: varians og standardfejl ved to perioder

Husk OLS-variansen. Under FD.1–FD.5:

$$\text{var}(\hat{\beta}_1^{FD} \mid \Delta\mathbf{x}) = \frac{\sigma^2_{\Delta u}}{\sum_i (\Delta x_i - \overline{\Delta x})^2}.$$

Estimér fejlledsvariansen fra FD-residualerne:

$$\widehat{\Delta u}_i = \Delta y_i - \hat{\delta}_0 - \hat{\beta}_1^{FD} \Delta x_i, \qquad \hat{\sigma}^2_{\Delta u} = \frac{\sum_i \widehat{\Delta u}_i^{\,2}}{n-2}.$$

Dermed er

$$se(\hat{\beta}_1^{FD}) = \sqrt{\frac{\hat{\sigma}^2_{\Delta u}}{\sum_i (\Delta x_i - \overline{\Delta x})^2}}.$$

n er antal individer. Ved heteroskedasticitet bruges robuste standardfejl.

Hvorfor pooled OLS kan være inkonsistent

I niveau er den udeladte fejl $a_i + u_{it}$. Efter kontrol for fælles tidseffekter giver SLR-formlen

$$\text{plim}\,\hat{\beta}_1^{OLS} = \beta_1 + \frac{\text{cov}(x_{it}, a_i) + \text{cov}(x_{it}, u_{it})}{\text{var}(x_{it})}.$$

- Selv hvis $\text{cov}(x_{it}, u_{it}) = 0$, kan $\text{cov}(x_{it}, a_i) \neq 0$ give bias.
- FE og FD fjerner a_i, fordi den er konstant over tid.
- Biasens fortegn afhænger af den økonomiske sammenhæng mellem a_i og x_{it}.

Kovarianser og varians henviser her til variablene efter fjernelse af tidseffekterne.

Politi og biltyverier: den økonomiske sammenligning

Efter terrorangrebet i Buenos Aires den 18. juli 1994 blev politiet placeret ved jødiske institutioner.

- Behandlingsgruppe: boligblokke med en beskyttet institution.
- Kontrolgruppe: boligblokke uden institution; de nærmeste naboblokke udelades.
- Udfald: gennemsnitlige biltyverier pr. blok pr. måned, april–juni og august–oktober.

En kausal fortolkning kræver, at andre følger af angrebet ikke ændrer biltyverier forskelligt i de to grupper. Forskydning af kriminalitet til kontrolområdet kan også påvirke sammenligningen.

Di Tella & Schargrodsky (2004), AER 94(1), 115–133.

Politi: fra DiD til første differenser

$$biltyverier_{it} = \beta_0 + \beta_1 institution_i + \beta_2 post_t + \beta_3 (institution_i \cdot post_t) + a_i + u_{it}.$$

Hvordan ser FD-modellen ud?

$$A: \quad \Delta biltyverier_i = \beta_0 + \beta_1 institution_i + \Delta u_i,$$
$$B: \quad \Delta biltyverier_i = \beta_0 + \beta_3 institution_i + \Delta u_i,$$
$$C: \quad \Delta biltyverier_i = \beta_2 + \beta_3 institution_i + \Delta u_i.$$

Vi bruger C: De permanente led forsvinder, og $\Delta post = 1$.

β_1 kan ikke estimeres separat fra et komplet sæt individ-FE i niveau.

Politi: udled FD-modellen

Sæt $post = 0$ før og $post = 1$ efter:

$$\begin{aligned} biltyverier_{i,\text{før}} &= \beta_0 + \beta_1 institution_i + a_i + u_{i,\text{før}}, \\ biltyverier_{i,\text{efter}} &= \beta_0 + \beta_1 institution_i + \beta_2 \\ &\quad + \beta_3 institution_i + a_i + u_{i,\text{efter}}. \end{aligned}$$

Træk før fra efter:

$$\Delta biltyverier_i = \beta_2 + \beta_3 institution_i + \Delta u_i.$$

- Konstantleddet i FD er ændringen for kontrolblokkene, β_2.
- β_3 er forskellen i ændringer: DiD-estimatet.

Politi: DiD- og FD-resultater

	Institution	Uden institution	Forskel
April–juni	0,113	0,096	0,017
August–oktober	0,041	0,114	−0,073
Ændring	−0,072	0,018	−0,090

Estimation	DiD-hældning	Robust SE
DiD	$-0,0903$	$0,0369$
FD	$-0,0903$	$0,0334$

- Ca. 0,09 færre tyverier pr. blok pr. måned, relativt til kontrolområdet.
- Almindelig robust DiD-SE ignorerer afhængighed mellem perioderne inden for blok.
- Med grupperede DiD-SE på blokniveau fås ca. 0,033, som ved FD.

Grupperede SE er ud over pensum. Kilde: egne beregninger på Di Tella–Schargrodsky-data.

FD-estimatoren: Quiz

"Sand" model:

$$\log(\mathit{timeløn}_{it}) = \beta_0 + \delta_0 d2_t + \beta_1 \mathit{udd}_{it} + \beta_2 \mathit{erfaring}_{it} + \beta_3 \mathit{lokalledighed}_{it} + \beta_4 \mathit{kvinde}_{it} + a_i + u_{it}.$$

FD estimationsmodel:

$$\Delta \log(\mathit{timeløn}_{i2}) = \delta_0 + \beta_1 \Delta \mathit{udd}_{i2} + \beta_2 \Delta \mathit{erfaring}_{i2} + \beta_3 \Delta \mathit{lokalledighed}_{i2} + \beta_4 \Delta \mathit{kvinde}_{i2} + \Delta u_{i2}.$$

Vil være muligt at estimere:

- β_4? Nej: køn er konstant for individet, så $\Delta \mathit{kvinde}_i = 0$.
- β_1? Kun hvis uddannelse ændrer sig. Her er variationen lille, så estimatet bliver upræcist.

FD med flere perioder og fælles tidseffekter

Med $T > 2$ bruger vi fælles tidseffekter:

$$y_{it} = \beta_0 + \beta_1 x_{it} + \lambda_t + a_i + u_{it}.$$

Første differenser giver

$$\Delta y_{it} = \beta_1 \Delta x_{it} + (\lambda_t - \lambda_{t-1}) + \Delta u_{it}.$$

- $T - 1$ differensobservationer pr. individ.
- Tidsdummier tillader en forskellig fælles ændring i hver periode.
- Kun ét konstantled ville påtvinge en lineær trend i niveau.
- Nabodifferenser deler et u og kan derfor være korrelerede.

Hvorfor FD.6 kan fejle, selv uden seriekorrelation i niveau

To nabodifferenser deler fejlleddet $u_{i,t-1}$:

$$\Delta u_{it} = u_{it} - u_{i,t-1}, \qquad \Delta u_{i,t-1} = u_{i,t-1} - u_{i,t-2}.$$

Hvis fejlleddene i niveau er ukorrelerede over tid med varians σ_u^2:

$$\begin{aligned} \operatorname{cov}(\Delta u_{it}, \Delta u_{i,t-1} \mid \mathbf{X}_i) &= \operatorname{cov}(u_{it} - u_{i,t-1}, u_{i,t-1} - u_{i,t-2} \mid \mathbf{X}_i) \\ &= -\operatorname{var}(u_{i,t-1} \mid \mathbf{X}_i) \\ &= -\sigma_u^2. \end{aligned}$$

- FD.6 er da ikke opfyldt: Der opstår negativ seriekorrelation.
- FD.1–FD.4 kan stadig holde. FD er da konsistent, men almindelige OLS-standardfejl for alle differensrækker er ikke gyldige.

FE: individgennemsnit

Fixed effects (FE) i toperiode-modellen:

$$y_{it} = \beta_0 + \beta_1 x_{it} + \delta_0 d2_t + a_i + u_{it}.$$

Individgennemsnit (time averages):

$$\bar{y}_i = \beta_0 + \beta_1 \bar{x}_i + \delta_0 \overline{d2} + a_i + \bar{u}_i. \tag{5}$$

Her er fx

$$\bar{x}_i = \frac{1}{T}\sum_{t=1}^{T} x_{it}, \qquad \overline{d2} = \frac{1}{T}\sum_{t=1}^{T} d2_t.$$

- **Between-variation:** Forskelle i gennemsnit mellem individer.
- a_i er konstant over tid og forsvinder derfor ikke ved at tage gennemsnittet.

FE: fjern individgennemsnittet

Within-transformation (demeaning): Træk individgennemsnittet fra.

$$y_{it} - \bar{y}_i = \underbrace{\beta_0 - \beta_0}_{0} + \beta_1(x_{it} - \bar{x}_i) + \delta_0(d2_t - \overline{d2}) + \underbrace{a_i - a_i}_{0} + (u_{it} - \bar{u}_i).$$

Wooldridges notation:

$$\ddot{y}_{it} = y_{it} - \bar{y}_i, \quad \ddot{x}_{it} = x_{it} - \bar{x}_i, \quad \ddot{u}_{it} = u_{it} - \bar{u}_i.$$

$$\ddot{y}_{it} = \beta_1 \ddot{x}_{it} + \delta_0 \ddot{d2}_t + \ddot{u}_{it}. \tag{6}$$

Within-variation: Afvigelser fra individets eget gennemsnit. Konstantleddet og den permanente heterogenitet er fjernet.

FE.1–FE.4: antagelser for fixed effects

- **FE.1: Lineær model** med additive, tidsinvariante individeffekter a_i og fælles hældninger.
- **FE.2: Tilfældig stikprøve af individer.**
- **FE.3: Ingen perfekt multikollinearitet.** Regressorerne skal variere inden for individer og må ikke være perfekt kollineære efter transformationen.
- **FE.4: Streng eksogenitet**

$$E(u_{it} \mid \mathbf{X}_i, a_i) = 0, \qquad t = 1, \ldots, T.$$

$\mathbf{X}_i$ indeholder alle individets regressorer i alle perioder.

FE.1–FE.4 svarer til FD.1–FD.4. FE er middelret og konsistent, når n vokser med T fast. Korrelation mellem a_i og x er tilladt.

FE-estimatoren: OLS efter demeaning

Her vises SLR-formlen uden fælles tidseffekter. Tidsdummier behandles på næste slide.

$$\ddot{y}_{it} = \beta_1 \ddot{x}_{it} + \ddot{u}_{it}.$$

Demeaning betyder, at $\sum_t \ddot{x}_{it} = 0$ for hvert individ. Derfor er også gennemsnittet over alle observationer nul:

$$\overline{\ddot{x}} = \frac{1}{nT} \sum_i \sum_t \ddot{x}_{it} = 0.$$

OLS-formlen reduceres til

$$\hat{\beta}_1^{FE} = \frac{\sum_{i,t} (\ddot{x}_{it} - \overline{\ddot{x}}) \ddot{y}_{it}}{\sum_{i,t} (\ddot{x}_{it} - \overline{\ddot{x}}) \ddot{x}_{it}} = \frac{\sum_{i,t} \ddot{x}_{it} \ddot{y}_{it}}{\sum_{i,t} \ddot{x}_{it}^2}.$$

FE og FWL: fjern individ- og tidseffekter

Within-transformationen fjerner individ-dummierne:

$$\ddot{x}_{it} = x_{it} - \bar{x}_i, \qquad \ddot{y}_{it} = y_{it} - \bar{y}_i.$$

- FWL: Regressér $\ddot{x}$ og $\ddot{y}$ på de transformerede tidsdummier, og tag residualerne.
- I et balanceret panel er residualerne $\ddot{x}_{it} - \overline{\ddot{x}}_t$ og $\ddot{y}_{it} - \overline{\ddot{y}}_t$.
- Regressér de to sæt residualer på hinanden uden konstantled.

Her er $\overline{\ddot{x}}_t = \frac{1}{n}\sum_i \ddot{x}_{it}$ periodens gennemsnit af den within-transformerede variabel.

FE med fælles tidseffekter

Her samler λ_t tidseffekterne; ved $T = 2$ er $\lambda_t = \delta_0 d2_t$. Efter demeaning:

$$\ddot{y}_{it} = \beta_1 \ddot{x}_{it} + (\lambda_t - \bar{\lambda}) + \ddot{u}_{it}.$$

FWL giver hældningen efter kontrol for tidseffekterne:

$$\boxed{\hat{\beta}_1^{FE} = \frac{\sum_{i,t}(\ddot{x}_{it} - \bar{\ddot{x}}_t)(\ddot{y}_{it} - \bar{\ddot{y}}_t)}{\sum_{i,t}(\ddot{x}_{it} - \bar{\ddot{x}}_t)^2}.}$$

- **FE.3:** Der skal være variation i $\ddot{x}$ efter kontrol for tid.
- Under FE.1–FE.4, herunder streng eksogenitet, er FE middelret og konsistent.

Ved to perioder er FE og FD identiske

Når $T = 2$, er within-transformationen

$$\ddot{x}_{i1} = x_{i1} - \tfrac{1}{2}(x_{i1} + x_{i2}) = -\tfrac{1}{2}\Delta x_i,$$
$$\ddot{x}_{i2} = x_{i2} - \tfrac{1}{2}(x_{i1} + x_{i2}) = \tfrac{1}{2}\Delta x_i.$$

Kontrol for tidsdummier centrerer ændringerne:

$$\ddot{x}_{i2} - \overline{\ddot{x}}_2 = \tfrac{1}{2}(\Delta x_i - \overline{\Delta x}),$$

og udtrykket for periode 1 har modsat fortegn. Derfor:

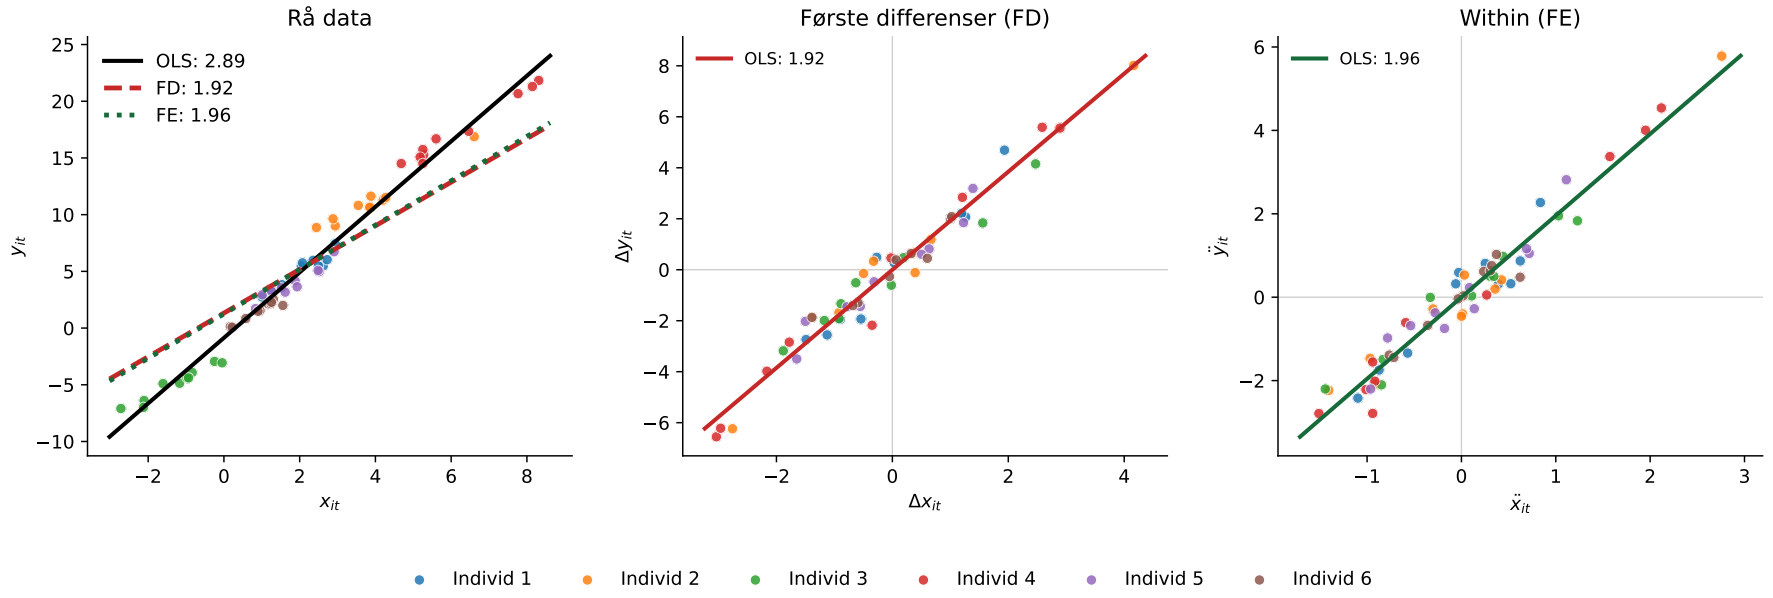
$$\hat{\beta}_1^{FE} = \frac{\sum_i (\Delta x_i - \overline{\Delta x})(\Delta y_i - \overline{\Delta y})}{\sum_i (\Delta x_i - \overline{\Delta x})^2} = \hat{\beta}_1^{FD}.$$

FE's $2n$ rækker indeholder samme information som FD's n differenser.

Paneldata i niveau, første differenser og within

$y_{it} = 1 + 2x_{it} + a_i + u_{it}, \quad x_{it} = 2 + a_i + v_{it}, \quad n = 6,\ T = 10.$

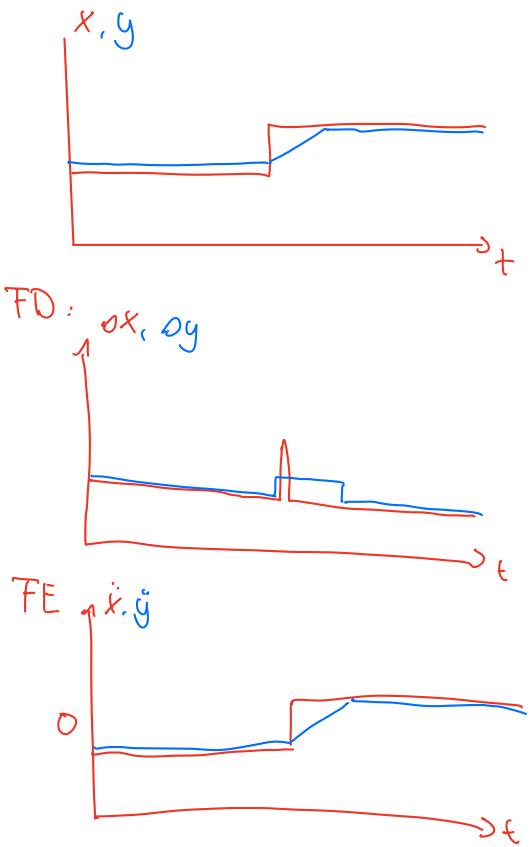
Uafhængige træk: $a_i \sim N(0, 6{,}25)$, $v_{it} \sim N(0, 1)$, $u_{it} \sim N(0, 0{,}25)$.



a_i og x_{it} er korrelerede. FD og within fjerner a_i. Sand hældning: 2.

I rå data viser FD/FE hældninger gennem $(\bar{x}, \bar{y})$, ikke fælles niveauregressioner.

FD og FE: to måder at fjerne niveauer



Rød er x, blå er y.

- Øverst: variablene i niveau.
- **FD:** $\Delta x_{it} = x_{it} - x_{i,t-1}$. Et spring bliver en kortvarig ændring.
- **FE / demeaning:** $\ddot{x}_{it} = x_{it} - \bar{x}_i$. Tidsforløbet bevares, men centreres omkring individgennemsnittet.

Ved $T > 2$ udnytter de derfor ikke variationen på samme måde.

FE.5–FE.6: hvornår er FE efficient?

Ud over FE.1–FE.4 antager vi:

- **FE.5: Homoskedasticitet i de oprindelige fejlled**

$$\text{var}(u_{it} \mid \mathbf{X}_i, a_i) = \sigma_u^2.$$

- **FE.6: Ingen seriekorrelation i de oprindelige fejlled**

$$\text{cov}(u_{it}, u_{is} \mid \mathbf{X}_i, a_i) = 0, \qquad t \neq s.$$

Under FE.1–FE.6 er FE den mest efficiente lineære middelrette estimator (BLUE).

FE.6 gælder for u_{it}, ikke for $\ddot{u}_{it}$. Demeaning skaber mekanisk korrelation mellem de transformerede fejl. FD.6 gælder derimod for Δu_{it}.

FE eller FD ved flere perioder?

- **FE.5–FE.6:** Homoskedastiske, ukorrelerede fejl i niveau gør FE efficient under FE.1–FE.4.
- **FD.5–FD.6:** Homoskedastiske, ukorrelerede differensfejl gør FD efficient under FD.1–FD.4 (fx en random walk i niveau).

Transformationerne ændrer fejlleddets kovarians. For ukorrelerede fejl i niveau med varians σ_u^2:

$$\operatorname{cov}(\ddot{u}_{it}, \ddot{u}_{is} \mid X) = -\frac{\sigma_u^2}{T}, \quad t \neq s,$$
$$\operatorname{cov}(\Delta u_{it}, \Delta u_{i,t-1} \mid X) = -\sigma_u^2.$$

Begge estimatorer kan være konsistente uden disse variansantagelser. Generel afhængighed inden for individ kræver grupperede standardfejl (ud over pensum).

RE: udnyt også variation mellem individer

Random effects (RE) bruger within- og between-variation. Det kræver eksogenitet af både a_i og u_{it}.

Den sammensatte fejl er $v_{it} = a_i + u_{it}$. Når a_i er ukorreleret med u, og u er homoskedastisk uden seriekorrelation:

$$\begin{aligned} \operatorname{cov}(v_{it}, v_{is}) &= \operatorname{cov}(a_i + u_{it}, a_i + u_{is}) \\ &= \operatorname{var}(a_i) = \sigma_a^2, \qquad t \neq s, \\ \operatorname{var}(v_{it}) &= \sigma_a^2 + \sigma_u^2. \end{aligned}$$

Derfor:

$$\operatorname{corr}(v_{it}, v_{is}) = \frac{\sigma_a^2}{\sigma_a^2 + \sigma_u^2}.$$

RE er GLS for denne kovariansstruktur. Standard-OLS-SE tager ikke højde for korrelationen.

RE er GLS med delvis demeaning

Partial demeaning (quasi-demeaning): Træk andelen θ af individgennemsnittet fra:

$$y_{it} - \theta\bar{y}_i = (1-\theta)\beta_0 + \beta_1(x_{it} - \theta\bar{x}_i) + (v_{it} - \theta\bar{v}_i),$$

$$\theta = 1 - \sqrt{\frac{\sigma_u^2}{\sigma_u^2 + T\sigma_a^2}}.$$

- $\theta = 0$: pooled OLS. $\theta = 1$: fuld demeaning (within).
- Ved endelig T og positive varianser ligger θ mellem 0 og 1.
- Vi estimerer varianskomponenterne til feasible GLS.

Konstantleddet bliver $(1-\theta)\beta_0$. Tidsdummier transformeres også. RE kræver stadig eksogenitet af a_i.

Simulation: permanent heterogenitet skaber bias

$$
\begin{aligned}
a_i &\sim N(0,4), \quad v_{it} \sim N(0,4), \quad u_{it} \sim N(0,1), \\
x_{it} &= 2 + v_{it} + a_i, \\
y_{it} &= 1 + 2x_{it} + a_i + u_{it}.
\end{aligned}
$$

De underliggende træk er indbyrdes uafhængige. Vi bruger $n = 500$ og $T = 2$.

- Sand hældning: $\beta_1 = 2$.
- Hvad er fortegnet på bias i pooled OLS?
- Holder RE-antagelsen, når a_i indgår i både x og y?

Efter resultaterne: eksperimentér i `Eksempler/14_paneldata_examples.ipynb`.

Simulation: OLS, FD, FE og faktisk RE

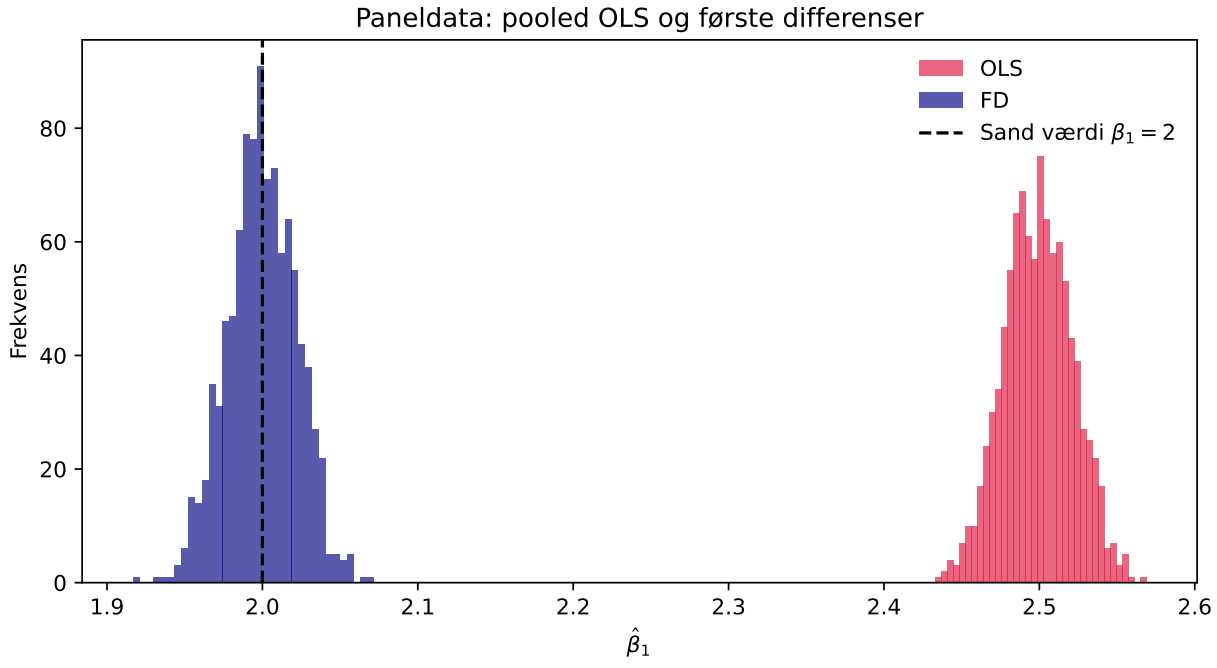
Estimator	OLS	FD	FE	RE
$\hat{\beta}_1$	2,4959	2,0046	2,0046	2,2818
SE($\hat{\beta}_1$)	0,0196	0,0223	0,0223	0,0196

Én stikprøve, $n = 500$, $T = 2$. Alle regressioner tillader fælles tidseffekter. SE er konventionelle modelbaserede standardfejl.

- FD og FE giver samme hældning og SE ved $T = 2$.
- OLS og RE bruger også between-variation, som her er endogen.
- En lille standardfejl gør ikke et inkonsistent estimat gyldigt.

Under DGP'en er plim $\hat{\beta}_1^{OLS} = 2 + \frac{4}{4+4} = 2{,}5$.

Simulation: stikprøvefordeling og konsistens



- 1.000 nye stikprøver med samme DGP. OLS ligger omkring 2,5; FD ligger omkring den sande værdi 2.
- Flere observationer gør fordelingen smallere. Det fjerner ikke OLS-biasen.

Andre typer panel data

Indtil nu har vi anvendt panel data i tid til at fjerne konstante individeffekter.

Vi kan bruge andre typer af "panel data" til at fjerne andre typer af effekter. Fx kan vi sammenligne

- søskende for at fjerne familie fixed effects.
- kollegaer for at fjerne virksomheds fixed effects.
- klassekammerater for at fjerne klasse fixed effects.

FE/FD-estimatoren på disse former for data udnytter, at der er variation i x inden for hvert "cluster" (familie, virksomhed, klasse).

Andre typer panel data: Eksempel

Estimates of the Economic Return to Schooling from a New Sample of Twins

By ORLEY ASHENFELTER AND ALAN KRUEGER*

This paper uses a new survey to contrast the wages of genetically identical twins with different schooling levels. Multiple measurements of schooling levels were also collected to assess the effect of reporting error on the estimated economic returns to schooling. The data indicate that omitted ability variables do not bias the estimated return to schooling upward, but that measurement error does bias it downward. Adjustment for measurement error indicates that an additional year of schooling increases wages by 12–16 percent, a higher estimate of the economic returns to schooling than has been previously found. (*JEL* J31)

Ashenfelter & Krueger (1994). The American Economic Review

Tvillingedata: en økonomisk lønmodel

$$\log(wage_{fj}) = \beta_0 + \beta_1 educ_{fj} + \alpha_f + u_{fj}, \qquad j = 1, 2.$$

- f er familie; j er tvilling. α_f samler de fælles, uobserverede forhold.
- u_{fj} samler individuelle forhold, som tvillingerne ikke deler.
- OLS kan få bias, hvis fx familiens ressourcer påvirker både uddannelse og løn.

Definér forskellen som tvilling 2 minus tvilling 1:

$$\Delta \log(wage_f) = \beta_1 \Delta educ_f + \Delta u_f.$$

α_f forsvinder. Identifikation bygger nu på forskelle inden for familier.

Tvillingedata: selektion og målefejl består

$$\Delta \log(wage_f) = \beta_1 \Delta educ_f + \Delta u_f.$$

- FD kræver eksogen uddannelsesforskel i forhold til Δu_f.
- Individuelle forskelle i helbred, evner og karriereplaner kan påvirke både uddannelse og løn.
- Målefejl kan fylde meget, når den sande uddannelsesforskel mellem tvillinger er lille.

FD.4 i tvillingemodellen: $E(u_{fj} \mid educ_{f1}, educ_{f2}, \alpha_f) = 0$. Observeret uddannelse $educ^*_{fj} + e_{fj}$ giver stadig målefejlen $e_{f2} - e_{f1}$ i differensen.

Fælles familiebaggrund forsvinder, men selektion og målefejl kan bestå.

Opsummering

Opsummering: gentagne tværsnit og DiD

- Gentagne tværsnit kan bruges til at undersøge, om betingede sammenhænge ændrer sig over tid.
- DiD sammenligner ændringen i en behandlingsgruppe med ændringen i en kontrolgruppe.
- Identifikation bygger på parallelle kontrafaktiske trends og en troværdig afgrænsning af indgrebet.
- Flere førperioder kan afsløre problemer, men ikke bevise antagelsen.
- Økonomisk teori hjælper os med at vurdere gruppers adfærd, selektion og mulige alternative forklaringer.

Opsummering: paneldata

- FE og FD fjerner tidsinvariant heterogenitet, selv når den er korreleret med x.
- **FD.1–FD.4 / FE.1–FE.4:** Konsistens kræver eksogene tidsvarierende fejl og variation efter transformationen.
- Streng eksogenitet: $E(u_{it} \mid x_{i1}, \ldots, x_{iT}, a_i) = 0$.
- FE og FD er identiske ved $T = 2$. **FD.5–FD.6 / FE.5–FE.6** afgør, hvornår de er efficiente.
- RE kan også bruge between-variation, men kræver eksogen permanent heterogenitet og en model for kovariansen.
- Tidsinvariante regressorer absorberes af individ-FE. Samme idé kan bruges til familie-, virksomheds- og klasseeffekter.